

ATAC 和 CUT&Tag 进阶手册：含生信代码

前 言

表观遗传学研究内容颇多,本书虽然大量篇幅介绍 ATAC 和 CUT&Tag 技术,但是甲基化研究也是表观遗传学研究的重点内容。后续有机会再单独更新甲基化相关内容。

2022 年 9 月,翌圣编写了第一版本《CUT&Tag 进阶手册》,详细描述了 CUT&Tag 实验原理、实验躲坑要点以及后续结果可视化展示,同时也展示了当时最新的文献报道。该书广受好评,但是美中不足的是没有添加 ATAC 相关内容。本次更新,在原来 CUT&Tag 实验基础上,增加了 ATAC 内容以及更新了最新的 ATAC 和 CUT&Tag 研究技术。

本书主要介绍 ATAC 和 CUT&Tag 技术原理,湿实验堵点以及干实验中数据分析流程。本书内容由团队合作撰写,大多是经验总结,可能有些内容无法文献论证,若有不专业或者错误地方,也请批评指正。

2025 年 9 月

责任编辑/校对/印刷: 翌圣 NGS 团队

责任设计: 翌圣 NGS 团队

版权所有,违者必究。未经本公司团队许可,数字图书不得使用。

(如有印刷质量问题,请联系翌圣免费更换)

目 录


第一章 表观遗传学概述	5
1.1 甲基化研究	5
1.2 组蛋白修饰	6
1.3 染色质重塑	6
1.4 非编码 RNA 调控	7
第二章 ATAC 技术简介、实验改造以及生信分析流程（含分析代码）	7
2.1 ATAC 技术介绍	7
2.2 ATAC 实验原理	9
2.3 ATAC 实验流程	12
2.3.1 ATAC 样本准备以及样本前处理	12
2.3.2 ATAC 实验操作（图文详解实验操作）	12
2.3.3 ATAC 技术应用	17
2.4 ATAC 相关衍生技术分享	17
2.5 ATAC 结果评估	19
2.5.1 ATAC-seq 上机测序前文库形态要求	19
2.5.2 ATAC-seq 测序分析数据的质控结果要求	19
2.6 ATAC 生信分析流程	21
2.7 ATAC 实验问题解决指南	21
第三章 CUT&Tag 技术简介、实验操作以及生信分析流程（含分析代码）	21
3.1 CUT&Tag 技术介绍	21
3.2 多靶标 CUT&Tag 技术介绍	25
3.3 CUT&Tag 实验操作（图文详解）	28
3.3.1 CUT&Tag 实验样本准备以及样本前处理	28
3.3.2 CUT&Tag 实验操作（图文详解实验操作）	28
3.4 CUT&Tag 实验躲坑妙招	36
3.4.1 甲醛交联与否	36
3.4.2 样本制备（此步骤非常重要，较好的样本制备是实验成功的必备条件） ..	37
3.4.3 抗体选择	38
3.4.4 样本捕获	39
3.4.5 gDNA 纯化	40
3.4.6 spike in 添加	40
3.4.7 文库库检	40
3.5 CUT&Tag 相关衍生技术分享	41
3.6 CUT&Tag 结果评估	43
3.7 CUT&Tag 生信分析流程	45
3.8 CUT&Tag 实验相关问题解决指南	45
附录一：ATAC/CUT&Tag 实验前样本准备	51

附录二：样本细胞核提取（图文详解实验操作）	52
附录三：ATAC/CUT&Tag 实验生信分析流程（附详细生信分析代码）	54
附录四：ATAC、ChIP-seq 或 CUT&Tag 公共数据库	87
附录五：转录因子预测网站分享	90

第一章 表观遗传学概述

1942 年，Conrad Waddington 最早提出 “表观遗传学 ” 这一概念，表观遗传通常被定义为 DNA 的序列不发生变化但是基因表达却发生了可遗传的改变，也就是说基因型未变化而表型却发生了改变，这种变化是细胞内除了遗传信息以外的其他可遗传物质的改变，并且这种改变在发育和细胞增殖的过程中能稳定的传递下去。

表观遗传学研究包含：DNA 甲基化、组蛋白修饰、染色质重塑以及非编码 RNA 调控。



图：表观遗传学内容

(Dai, W., Qiao, X., Fang, Y. et al. Sig Transduct Target Ther 9, 332 (2024))

1.1 甲基化研究

甲基化是指在核酸或者蛋白质上添加甲基基团的化学反应。它在基因表达中起着非常重要的作用，通常通过影响基因的可及性来抑制基因表达。甲基化包含：

- ◆ DNA 甲基化：DNA 甲基化 (DNA methylation) 是指将甲基基团共价添加到 DNA 分子上的表观遗传修饰方式。甲基化类型有腺嘌呤的 N-6 位 (6mA)、胞嘧啶的 N-4 位、鸟嘌呤的 N-7 位 (7mG) 和胞嘧啶的 C-5 位 (5mC) 等。DNA 甲基化研究技术有 WGBS、RRBS、OxBS、EM-seq、eTAPs、tBS 等。
- ◆ RNA 甲基化：在甲基转移酶的催化下，RNA 的甲基腺嘌呤被选择性地添加甲基基团的

化学修饰现象。主要在转录后水平上调控基因表达。目前 RNA 甲基化主要研究 m6A。RNA 甲基化研究技术主要是 m6A-seq、MeRIP、miCLIP 等。

- ◆ 组蛋白甲基化:组蛋白修饰是组蛋白在酶催化下发生甲基化、乙酰化等化学修饰的过程,通过改变染色质结构调控基因表达,形成“组蛋白密码”。主要修饰包括乙酰化、甲基化、磷酸化及泛素化。修饰位点集中在组蛋白 N 端尾部,与 DNA 甲基化协同参与转录调控组蛋白修饰。目前广为研究的是组蛋白甲基化修饰,不同的修饰位点,起到的作用不同,如 H3K4 甲基化激活基因, H3K9、H3K27 甲基化则介导基因沉默。组蛋白修饰主要研究技术有 CUT&Tag、CUT&RUN、ChIP-seq 等。

1.2 组蛋白修饰

组蛋白修饰是组蛋白在酶催化下发生甲基化、乙酰化等化学修饰的过程,通过改变染色质结构调控基因表达,形成“组蛋白密码”。主要修饰包括乙酰化、甲基化、磷酸化及泛素化。修饰位点集中在组蛋白 N 端尾部,与 DNA 甲基化协同参与转录调控组蛋白修饰。

- ◆ 组蛋白甲基化是由组蛋白甲基化转移酶 (histonemethyl transferase, HMT) 完成的。甲基化可发生在组蛋白的赖氨酸和精氨酸残基上,而且赖氨酸残基能够发生单、双、三甲基化,而精氨酸残基能够单、双甲基化,这些不同程度的甲基化极大地增加了组蛋白修饰和调节基因表达的复杂性。
- ◆ 组蛋白乙酰化主要发生在 H3、H4 的 N 端比较保守的赖氨酸位置上,是由组蛋白乙酰转移酶 (HAT) 和组蛋白去乙酰化酶 (HDACs) 协调进行。组蛋白乙酰化呈多样性,核小体上有多个位点可提供乙酰化位点,但特定基因部位的组蛋白乙酰化和去乙酰化是以一种非随机的、位置特异的方式进行。
- ◆ 蛋白质磷酸化反应是指三磷酸腺苷(ATP)末位(γ 位)的磷酸转移到基质蛋白质的特定氨基上所进行的共价修饰的一类反应的总和。生物体内存在着大量的磷酸化激酶,蛋白质磷酸化在生物体内广泛存在。而组蛋白磷酸化修饰功能的保守性不强,在基因表达调控过程中,具有激活或者抑制基因表达的功能,需要根据实际情况去分析。
- ◆ 组蛋白泛素化与其他组蛋白翻译后修饰有很大不同,需要与 76 个氨基酸的蛋白质共价结合。泛素化是 E1 激活酶、E2 结合酶和 E3 连接酶依次作用的结果,导致泛素 (Ub) 与蛋白质上的赖氨酸残基或 Ub 本身共价结合,形成不同类型的多聚泛素链。同时,去泛素化酶 (DUB) 负责去除这些泛素化标记。

1.3 染色质重塑

染色质重塑 chromatin remodeling 是指通过转录因子、组蛋白修饰酶、ATP 依赖的重塑复合物等调节因子,调控染色质结构的过程。染色质重塑能够改变核小体密度、核小体组装方式,甚至调整整个染色质区域的三维结构。这种结构上的改变直接影响到染色质的可及性和基因的转录活性。

染色质重塑通过改变染色质的结构,特别是在增强子和启动子区域,可以调节染色质的可及性。这种调节过程是基因表达调控的重要机制之一。染色质重塑过程,大多是有重塑因子复合物联合发挥作用。染色质重塑因子如 SWI/SNF 家族、ISWI 家族等,通过 ATP 依赖的机制,能够调整染色质的结构,从而影响染色质可及性,进而影响基因的表达水平和模式。

1.4 非编码 RNA 调控

非编码 RNA 是指不编码蛋白质的 RNA，包括核糖体 RNA (rRNA)、转运 RNA (tRNA)、核小 RNA (snRNA)、核仁小 RNA (snoRNA)、微小 RNA (miRNA) 等，以及其他一些功能已知和功能未知的 RNA。这些 RNA 的共同特点是从基因组转录但不翻译成蛋白质，但是会在 RNA 水平上发挥各自的生物学功能。

- ◆ <50 nt: 微小 RNA (miRNA) : miRNA 与 mRNA 互补，促使 mRNA 沉默或降解。小干扰 RNA (siRNA) : 沉默基因表达。
- ◆ 50~500 nt: 核仁小 RNA (snoRNA) : snoRNA 的生物学功能最初被发现于修饰 rRNA。核小 RNA (snRNA) : 与蛋白质结合形成核小核糖蛋白颗粒，起到剪接 mRNA 的作用。转运 RNA (tRNA) : 主要功能是携带氨基酸进入核糖体，在 mRNA 的引导下合成蛋白质。最初 tRNA 大多会被认为是管家基因，在生物体内稳定表达。近几年研究表明，tRNA 能参与表观调控。核糖体 RNA (rRNA) : 与蛋白质结合形成核糖体，作为 mRNA 的支架，使 mRNA 分子在其上展开，实现蛋白质的合成。
- ◆ >500 nt: 长链非编码 RNA (lncRNA) : lncRNA 作为 mRNA 和 miRNA 竞争性内源 RNA，调控基因表达。环状 RNA (circRNA) : 环状 RNA 分子富含 miRNA 结合位点，在细胞内竞争性结合 miRNA，从而解除 miRNA 对靶基因的抑制，提高靶基因的表达水平。

第二章 ATAC 技术简介、实验改造以及生信分析流程 (含分析代码)

2.1 ATAC 技术介绍

ATAC-seq, Assay for Transposase-Accessible Chromatin with highthroughput sequencing, 即利用转座酶探究可接近性染色质高通量测序技术，可以研究细胞特定状态下开放的染色质区域和相关基因信息。里面涉及到几个概念：

- ◆ 常染色质: Euchromatin, 间期细胞核内染色质纤维折叠压缩程度低，相对处于伸展状态，用碱性染料染色时着色浅的染色质。
- ◆ 异染色质: Heterochromatin, 间期细胞核内染色质纤维折叠压缩程度高，处于聚缩状态，用碱性染料染色时着色深的染色质。
- ◆ 开放染色质区域: Open Chromatin Region, 开放染色质区域是一段允许转录因子和其他调控元件结合的 DNA 区域。染色质是由 DNA 和组蛋白结合形成核小体后再进一步折叠压缩形成的状态。DNA 的复制和转录都需要将致密染色质结构打开，染色质结构打开后，转录因子或者其他调控元件结合在该区域后对基因的表达进行调控。这部分被打开的染色质叫做开放染色质区域。而仍然处理致密状态的染色质，称为异染色质区域。
- ◆ 染色质可及性: Chromatin Accessibility, 开放染色质允许调控因子结合的特性称为染色质的可及性。
- ◆ Linker DNA: 染色质上核小体和核小体之间的区域称为 linker DNA。Linker DNA 的长度会根据染色质的浓缩状态发生变化，且不同物种的 linker DNA 的长度也不一样。通

常实验时能切割到的 linker DNA 长度为 40~70 bp。

- ◆ 核小体特征峰：ATAC 切割时，会呈现明显的特征峰，第一条峰为 linker DNA 的峰，第二条峰为核小体+linker DNA 的峰，第三条峰为两个核小体+linker DNA 的峰。如果做核小体定位，需要第四个甚至第五个峰。带有核小体的峰会以 200 bp 为单位呈现 200 bp、400 bp、600 bp 这样大小的分布趋势。
- ◆ 转录因子：转录因子（Transcription factors、TFs）是一类能够与特定 DNA 序列结合，并控制基因转录起始活性的蛋白质因子。转录因子基本结构可分为三部分：①DNA 结合结构域，主要负责识别并结合 DNA 序列，如碱性螺旋-环-螺旋（bHLH）、碱性亮氨酸拉链（bZIP）、螺旋-转角-螺旋（HTH）和锌指等。②反式激活结构域（或转录激活结构域），负责与其他蛋白质结合，调节转录活性。③信号感知结构域，负责感受外界刺激并把信号传递给转录复合物，调节基因转录，但并非所有转录因子都具有信号感知结构域。这些结构域决定了转录因子的功能和特性。ATAC 实验，可以鉴定到开放染色质区域结合的转录因子。酵母双杂交或者双荧光素酶报告基因检测来鉴定转录因子，就是利用转录因子的 DNA 结合结构域和转录激活结构域。
- ◆ 基因表达调控：基因表达调控是指从 DNA 到蛋白质的调节过程，是生物体内基因表达的调节控制，使细胞中基因表达的过程在时间、空间上处于有序状态，并对环境条件的变化作出反应的复杂过程。基因表达调控可在多个层次上进行，包括基因水平、转录水平、转录后水平、翻译水平和翻译后水平的调控。转录因子通常会在转录水平上影响基因的表达，因而 ATAC-seq 通常也会联合 RNA-seq 做多组学研究，进一步探寻基因表达调控机理。
- ◆ 基因启动子区域：启动子是基因转录的特定 DNA 区域，通常位于基因转录起始位点的 5' 端上游，长度约为 100-1000 bp。在数据分析时，启动子区域通常会设置在基因起始转录位置上游 2 kb 或者 5 kb。

染色质开放性研究技术，除了 ATAC-seq 之外，还有 DNase-seq、FAIRE-seq、MNase-seq、NOMe-seq 等。每种技术有自己的特点，目前基于 ATAC-seq 操作的便捷性以及技术的应用性强等（如单细胞方向），其他技术使用的人已经大大缩减了。ATAC-seq 目前已经成为研究染色质可及性的主流技术。

表：五种不同染色质开放性检测技术介绍

技术	细胞量要求	原理	目的	优缺点
ATAC-seq	10~10 ⁵	Tn5 转座酶空 间切割	获取染色质可 及性、转录因子 结合以及核小 体定位信息	过程简单、效率高； 实验重复性好； 需要先分离出细胞核； 存在细胞器污染，可提高前处理 流程来减少细胞器污染； 数据质量受样本状态影响较大。
DNase-seq	10 ⁶ ~10 ⁷	DNase I 切割	获取染色质开 放信息	细胞起始投入量大； 最优酶量确认过程繁琐；

				样品制备过程复杂且耗时。
FAIRE-seq	105~107	超声波物理断裂	获取染色质开放信息	不用酶切、不需要分离出细胞核； 没有序列切割特异性； 细胞起始投入量大； 需要甲醛交联且最佳甲醛交联程度难以确认。
MNase-seq	106~107	微球菌核酸酶切割	绘制核小体图谱以间接探测染色质可及性	操作简单，后期数据处理方便； 细胞起始投入量大； 酶用量以及切割温度难以确认，实验难以标准化。
NoMe-seq	106	甲基化修饰	获取内源 DNA 甲基化的信息并定位核小体	不需要 DNA 断裂，不会产生富集偏差； 同时获得含 GpC 和 CpG 二核苷酸的信息； 细胞起始投入量大。


2.2 ATAC 实验原理

Tn5 结构以及 Tn5 文库构建原理

——常规 DNA 建库、ATAC-seq 文库和 CUT&Tag 文库通用


在 NGS 领域，Tn5 酶算是明星了。不管是表观建库如 ATAC-seq、CUT&Tag 还是在急速建库领域抑或是一步法建库技术等等，Tn5 都是主角的存在。那 Tn5 酶是怎么完成建库的呢？各位看官请听小翌详说。

原始 Tn5 酶是由两个 1.5 kb 的 IS50 插入序列夹带的抗生素耐药区组成，IS50L 和 IS50R。它是通过多步骤酶切-粘贴机制行使功能。具体为：两分子 Tn5 转座酶单体首先结合到 IS50 元件末端的两个 19 bp 区域（OE 序列和 IE 序列），然后通过二聚体形成突触复合体；转座酶促进重组的三个核心步骤 1) 这些蛋白质可以识别移动元件末端的特定 DNA 序列，并将它们配对形成突触复合体；2) 这些蛋白质在元件的每一端切割 DNA，将元件的 3'OH 端从嵌入的 DNA 中解放出来；3) 这些蛋白质促进新的 DNA 位点上的末端的两个磷酸二酯键被攻击，从而将元件的基因组连接到新的 DNA 片段。水在裂解阶段扮演亲核试剂的攻击角色，而元件的 3'羟基在 DNA 连接阶段(称为 DNA 链转移)扮演亲核试剂的角色【1】。



图：Tn5 转座机制【2】

Tn5 发展到现在，人们已经能够利用 Tn5 进行体外酶切实验，也是我们现在利用 Tn5 酶来进行文库构建的方式。研究者发现，体外 Tn5 实验，只需要核心序列（ME：CTGTCTCTTATACACATCT）、Tn5 转座酶以及 Mg^{2+} 就能够行使 Tn5 “剪切-复制”功能。因而利用这种原理，科学家们将含测序接头序列一致的序列添加到 ME 序列中，在转座酶“剪切-复制”时，将 ME 序列插入靶 DNA 序列的同时，加上测序序列，从而在后续建库扩增过程中，实现一步法 PCR 建库就能获得完整的用于测序的文库。



图：含不同测序引物的 tn5 酶应用场景【2】

当然，Tn5 酶虽然有这么强的优势，但是也有一定的缺陷，就是 Tn5 酶在“剪切”位点末端，具有 9bp 的碱基偏好性。那看到这里，可能有人会问，既然有碱基偏好性，Tn5

酶是不是像常用的限制性内切酶一样有识别位点呢？为什么我们一直说 Tn5 酶是随机切割呢？实际上，Tn5 酶确实是有识别位点，但是识别位点并非像限制性内切酶一样序列特异。目前共识的 Tn5/IS50 目标位点为 A-GNTYWRANC-T。当然，看到这里，可以还是有人会问，那我们做像 ATAC、CUT&tag 这样的表观实验，如果 Tn5 有目标识别序列，是不是效果就不太好？这里又得说到 Tn5 转座的另一个特性，就是它会优先整合到主动转录或高度超卷曲的 DNA 区域中，这种特性就与序列特异性无关，而是与靶标的拓扑结构有关【3】。

讲了这么多的原理，那在 Tn5 建库过程中，含有 ME 序列和接头序列的包埋序列，是如何进行建库的呢？


我们以常用的含 Illumina 测序 adapter 的 ME 为例，来给大家详细讲解吧。

首先，隆重出场的是转座酶复合体。转座酶复合体是由两分子的 Tn5 转座酶加两端 DNA 序列，具体情况见下图：



图：Tn5 转座酶结构

转座酶复合体组合后，我们就可以进行文库构建了，Tn5 转座复合体进行“剪切-复制”的过程中，会在靶 DNA 处产生一个 9 bp 的 gap，在文库构建的 PCR 阶段，需要先进行 72℃ 的延申步骤来补平 gap，具体步骤见下图：



图：Tn5 文库构建流程

大家对 Tn5 酶进行文库构建是否明白了呢？

参考文献：

[1] Rice P A , Baker T A . Rice PA, Baker TA. Comparative architecture of transposase and integrase complexes. Nat Struct Biol 8: 302-307[J]. Nature Structural Biology, 2001, 8(5):302-307.

[2] Li N , Jin K , Bai Y , et al. Tn5 Transposase Applied in Genomics Research[J]. International Journal of Molecular Sciences, 2020, 21(21):8329.

[3]Goryshin, Igor Y , Miller, et al. Tn5/IS50 target recognition.[J]. Proceedings of the National Academy of Sciences of the United States of America, 1998.

2.3 ATAC 实验流程




图 ATAC-seq 试剂盒原理

ATAC 实操图文讲解

2.3.1 ATAC 样本准备以及样本前处理

ATAC/CUT&Tag 实验前，需要准备样本。实验样本可以是新鲜细胞或者组织、新鲜植物组织或者冻存细胞/组织、冻存植物样本。不同样本的保存以及实验前样本量要求，见本书附录一。

样本准备完成后，需要对样本进行提核处理。提核实验的部分，ATAC 以及 CUT&Tag 实验都能够通用，因而该步骤放在本书最后，见本书附录二。

2.3.2 ATAC 实验操作（图文详解实验操作）

ATAC 试剂组分以及原理

组分编号			组分名称	原理
BOX I	12208-A	⊖	Wash Buffer	细胞缓冲液
	12208-B	●	Terminate Solution	转座终止 buffer
	12208-C	○	DNA Extract Beads	DNA 纯化磁珠，有效回收小于 100 bp 片段
	12208-D	○	DNA Clean Beads	DNA 纯化磁珠，回收效率高，文库浓度高
BOX II	12208-E	●	Suspension Buffer	细胞核打孔
	12208-F	●	1 % Digitonin	
	12208-G	●	10% Tween-20	

	12208-H	○	10% NP40	
	12208-I	●	Reaction Buffer	转座酶工作缓冲液
	12208-J	●	Transposome Mix	转座酶
	12208-K	⦿	Canace® Pro Amplification Mix	文库扩增酶
	12208-L	○	N5 (N501)*	I5 端 index
	12208-M	○	N7 (N701)*	I7 端 index

ATAC 实验操作流程与时间

溶液配置 (0.5 h) → 细胞收集与裂解 (0.5 h) → 转座酶片段化 (0.5~1 h) → 基因组 DNA 回收 (0.5 h) → 文库扩增 (0.5~1 h) → 文库分选与质检 (0.5~1h)

ATAC 建库流程详解

① 准备材料

1. 文库质检：Agilent 2100 Bioanalyzer DNA 1000 Chip/ High Sensitivity Chip 或其他等效产品、文库定量试剂。
2. 其他材料：无水乙醇、无菌超纯水、台盼蓝、常温离心机、低温冷冻离心机、显微镜、血球计数板、1.5mL 离心管、移液器及对应的低吸附枪头、PCR 管、磁力架、PCR 仪等。40 μ m 细胞筛、无菌刀片、5cm 培养皿、PBS、组织匀浆器（用于组织样本）。
3. Hieff NGS® Tagment Index Kit for Illumina® (Cat#12416) 或其他替代引物。
4. ATAC 建库试剂盒 (12208ES)

② 细胞收集与裂解（此处裂解作用主要是为了打孔方便后续各种大分子进入细胞核内）

1. 在室温下收获细胞并计数，取实验所需数量的细胞于 1.5 mL EP 管中，4°C 2,300 rpm (500 $\times$ g) 离心 5 min，吸净管内溶液。

【注】：对于大小不同的细胞，请根据实际情况调整离心力。

2. 每个样本加入 50 μ L 预冷的 Wash Buffer 重悬细胞，4°C 2,300 rpm (500 $\times$ g) 低速离心 5 min，吸净管内溶液。
3. 每个样本中加入 50 μ L Lysis Buffer，轻轻吹打重悬，冰上放置 5 min，4°C，2,300 rpm (500 $\times$ g) 离心 5 min，去除上清。


【注】：此步很关键，需要注意小心的去除 Lysis Buffer，不要造成细胞核的损失，建议不要完全吸干净液体，可保留不超过 5 μ L 的液体。可以在这步配制后续的 Transposition Mix。

4. 直接进行后续的转座反应。

【注】：处理好的细胞核应及时加入 Transposition Mix 进行片段化反应，否则细胞核长时间暴露于空气中，可能会导致细胞核损伤，后续建库出现高的背景噪音。



1、计数 2、取相应数量 cell (60w) 3、4°C 离心 4、离心后 5、弃上清 6、加PBS轻轻吹打混匀(1.2ml)



7、取5w cell (100 μ L) 8、4°C 离心5min 9、离心后（可能看不见沉淀） 10、弃上清（保留一定体积） 11、配制lysis buffer



12、加入lysis buffer 13、冰上裂解5 min 14、取5 μ L 镜检 15、裂解完离心 16、离心后 17、弃上清（注意留取液体5-10 μ L）

③转座酶片段化

于无菌 PCR 管中配制表 2 所示反应体系，配制好后冰上放置。

表 2 Transposition Mix 反应体系


名称	体积 (μ L)
Reaction Buffer	25 μ L
Transposome Mix	2 μ L
Wash Buffer	16.5 μ L
1% Digitonin	0.5 μ L
10% Tween-20	0.5 μ L
Nuclease-free ddH ₂ O	Up to 50 μ L

2. 将配制好的 Transposition Mix 加入到处处理好的细胞核中，使用移液器轻轻吹打 5-8 次混匀。

【注】：吹打时尽量轻柔缓慢，不要产生气泡，否则会对细胞核造成损伤。也不要离心，否则会导致细胞核聚集，导致片段化不充分。

3. 将上述 PCR 管置于 PCR 仪中，37°C 30 min，进行片段化反应。


4. 将反应结束后的 PCR 管瞬离，立即向每个样本中加入 5 μ L 的 Terminate Solution，用移液器轻柔吹打 20 次混匀，室温静置 5 min。



18、配制转座mix 19、加入转座mix，轻轻吹打混匀 20、转管 21、pcr仪孵育

④基因组 DNA 回收

- 1. 将平衡至室温的 DNA Extract Beads 磁珠，涡旋振荡混匀。
- 2. 吸取 130 μL DNA Extract Beads 至 55 μL 终止后的片段化产物中，涡旋混匀或用移液器吹打混匀 10 次，室温静置孵育 5 min。
- 2. 短暂离心，将离心管置于磁力架上静置 3 min，待磁珠完全贴壁后吸净 PCR 管中溶液。
- 3. 保持 PCR 管始终处于磁力架上，从另一侧加入 200 μL 80%乙醇，避免直接冲洗磁珠，静置 30-60 sec，吸净 PCR 管中溶液。
- 4. 保持 PCR 管始终处于磁力架中，再次加入 200 μL 80%乙醇，静置 30-60 sec，吸净 PCR 管中溶液。
- 5. 保持 PCR 管始终处于磁力架上，开盖空气干燥至磁珠刚刚出现龟裂(不超过 3 min)。
- 6. 从磁力架上取下 PCR 管，加入 25 μL ddH₂O，并充分涡旋，室温静置 5 min。



- 7. 将 PCR 管短暂离心并置于磁力架上分离磁珠和液体，待溶液澄清后(约 3-5 min)，小心转移 23 μL 上清至新的 PCR 管中，进行后续的文库扩增或者-20℃保存。

⑤文库扩增与纯化

文库扩增

- 1. 将表 4 中试剂解冻后颠倒混匀，瞬离后置于冰上备用。
- 2. 于无菌 PCR 管中配制表 4 所示反应体系。

表 4 PCR 扩增反应体系

名称	体积 (μL)
步骤 3.4 纯化产物	23
N5XX*	1
N7XX*	1
Canace® Pro Amplification Mix	25

【注】：*Hieff NGS® Tagment Index Kit for Illumina® (Cat#12416) 中提供多种 N5XX 和 N7XX，可根据样品数量和 Index 选择策略自行选择。

- 3. 使用移液器轻轻吹打或振荡混匀，并短暂离心将反应液收集至管底。
- 4. 将 PCR 管置于 PCR 仪中，设置表 5 所示反应程序，进行 PCR 扩增。

表 5 PCR 扩增反应程序

温度	时间	循环数
----	----	-----


热盖 105°C	On	
72°C	3 min*	---
98°C	1 min	---
98°C	10 sec	n cycles**
60°C	25 sec	
72°C	1 min	---
4°C	Hold	---

【注】：*此步不可省略，转座反应产物并非完整的双链 DNA，72°C 孵育 3 min 用于生成成熟的 PCR 模板。

由于起始细胞量以及不同种类细胞的染色质开放状态差异，文库大小可能存在不同的分布模式。通过磁珠分选，文库中的大片段可以有效去除，使得文库片段分布在 200-700 bp 左右。

磁珠分选

1. 进行双轮分选的比例推荐 $0.55\times/1.0\times$ ，吸取 27.5 μL ($0.55\times$ ，Beads:DNA=0.55:1) 平衡至室温的 DNA Clean Beads 至步骤 3.5 的 PCR 反应产物中，涡旋混匀或用移液器吹打混匀 10 次，室温静置孵育 5 min。
2. 短暂离心，将 PCR 管置于磁力架上静置 5 min，待溶液澄清后，小心转移上清至新的 PCR 管中(残留 3-5 μL ，避免吸到磁珠)。
3. 涡旋振荡混匀 DNA Clean Beads 并吸取 50 μL ($1.0\times$ ，Beads:DNA=1:1) 至上清中，涡旋混匀或移液器吹打混匀 10 次，室温静置孵育 5 min。
4. 短暂离心，将 PCR 管置于磁力架上静置 3 min，待磁珠完全贴壁后吸净 PCR 管中溶液。
5. 保持 PCR 管始终处于磁力架上，从另一侧加入 200 μL 80%乙醇，避免直接冲刷磁珠，静置 30-60 sec，吸净 PCR 管中溶液。



6. 保持 PCR 管始终处于磁力架上，再次加入 200 μL 80%乙醇，静置 30-60 sec，吸净 PCR 管中溶液。
7. 保持 PCR 管始终处于磁力架上，开盖空气干燥至磁珠刚刚出现龟裂(不超过 3 min)。
8. 从磁力架上取下 PCR 管，加入 21 μL ddH₂O，并充分涡旋，室温静置 5 min。

⑥文库质检

通常情况下，对构建好的文库进行浓度和长度分布检测，具体请参见注意事项，主要包括：

- a. 浓度检测：用 Qubit 对文库的浓度进行检测。
- b. 质量检测：用 Qsep 或者安捷伦 2100 检测文库片段分布。




图 2 ATAC 文库 Agilent 2100 检测结果

转座酶切割核小体时，ATAC 文库需要有明显的核小体模型分布，ATAC 文库第一个文库分布在 170-200bp 左右，为核小体 Free 模型；后面出现的第二个峰为一个核小体模型，可能会出现两个核小体模型。如果酶量相对细胞过量，则文库可能只有核小体 Free 模型，即只有一个主峰。

2.3.3 ATAC 技术应用


ATAC 技术问世以来，广受好评。至今已经应用在不同的方向上，概况下来应用方向有：

- ◆ 染色质开放区域图谱绘制。
- ◆ 多组学联用，找寻转录因子调控的靶基因。
- ◆ 识别启动子区域，还能鉴定潜在的增强子或沉默子。
- ◆ 核小体定位。
- ◆ 比较不同处理的样本中转录因子结合情况差异，鉴定关键调控因子。
- ◆ 鉴定具体细胞特异性的转录因子及其结合位点。

2.4 ATAC 相关衍生技术分享

文献一：CH-ATAC-seq 技术：微孔板 ATAC 实现多标记额单细胞 ATAC

良渚实验室/浙江大学基础医学院郭国骥教授团队 Fast and flexible profiling of chromatin accessibility and total RNA expression in single nuclei using Microwell-seq3 (Cell Discovery, 2024) 和 Construction of Single-Cell Cross-Species Chromatin Accessibility Landscapes with combinatorial-hybridization-based ATAC-seq (Development Cell, 2024) 上发表的在微孔中做 ATAC 实验，实现了 ATAC 与单细胞技术的结合。




图：CH-ATAC-seq 实验流程

CH-ATAC-seq 是一种基于组合杂交的单细胞染色质可及性技术。首先，细胞核在 4 个 96 孔板内经过转座反应打上第一轮共 384 种标签。然后，细胞核被收集混匀并均匀分布到新的 96 孔板进行杂交反应，并引入第二轮共 768 种标签。最后，细胞核再次收集并分布到 96 孔板进行 PCR 反应，引入最后一轮共 384 种标签。理论上，单次实验可以处理百万级别的细胞核，并且多个样本可以进行通过第一轮标签进行标记后混到一起处理，大大减少了样本间的批次效应。

文献二：Tn5 结合甲基化技术，实现单细胞甲基化流程

北京大学生物医学前沿创新中心 (BIOPIC) / 昌平实验室谢晓亮课题组 2023 年在 PNAS 在线发表了题为 “Single-cell bisulfite-free 5mC and 5hmC sequencing with high sensitivity and scalability” 的研究论文，介绍了不依赖重亚硫酸盐转化的高基因组覆盖度单细胞甲基化与羟甲基化测序技术——Cabernet。



图：Cabernet 实验流程

研究团队利用 Tn5 转座时引入序列标签组合，通过差异标签化的单细胞混合转化建库的方式进一步建立了高通量 DNA 甲基化检测平台。该方法兼备成本效益的同时，能够在两天时间高效实现数以千计的单细胞 DNA 甲基化检测。

2.5 ATAC 结果评估

2.5.1 ATAC-seq 上机测序前文库形态要求

对于 ATAC 文库，插入片段长度分布是评估文库质量的一个重要指标。ATAC 文库构建完成后，除了要评估文库的浓度以便于后续测序外，还需要评估 ATAC 文库的片段分布。最好 ATAC 文库的片段分布检测在合理范围再送测序，否则可能就浪费了测序费用了。

根据 ATAC-seq 的原理和测序情况，reads 长度分布应该是下降的，但是对于无核小体区域（核小体 free 区域，nucleosome-free regions, NFR）以及单、双、三甚至更多核小体的长度处有凸起小峰。在实际实验过程中，NFR 丰度、单核小体丰度以及双核小体丰度的分布不一定是呈现下降趋势。

1 个核小体中的 DNA 序列约为 147 bp，这些序列被切割回收后，其长度依次在~50 bp（NFR）、~200 bp（单核小体）、~400 bp（双核小体）、~600 bp（三核小体）附近，因此插入片段的长度分布图一般会呈现出波浪型的形状。仔细观察分布图细节，还能看到以 10.5 bp（DNA 螺距）为周期的小峰的周期性分布，这些小螺距是 DNA 双螺旋结构的位阻效应导致的。





图 2 ATAC 文库 Agilent 2100 检测结果

转座酶切割核小体时，ATAC 文库需要有明显的核小体模型分布，ATAC 文库第一个文库分布在 170-200bp 左右，为核小体 Free 模型；后面出现的第二个峰为一个核小体模型，可能会出现两个核小体模型。如果酶量相对细胞过量，则文库可能只有核小体 Free 模型，即只有一个主峰。

2.5.2 ATAC-seq 测序分析数据的质控结果要求

ATAC-seq 数据下机后，质控一般会看 fragment 分布、TSS-TES 分布图、peak 数、FRIP 值以及 IGV 可视化上 peak 的噪音程度和 peak 是否主要落在启动子区域。



图：ATAC 数据插入片段长度分布图

ENCODE 全 称 是 The Encyclopedia of DNA Elements Consortium (<https://www.encodeproject.org/data-standards/atac-seq/atac-encode4/>)，是一个由 NHGRI（国家人类基因组研究所）资助的研究组够成的协会，其主要目的是建立全面的人类基因组中的功能元件列表，包括作用于蛋白和 RNA 水平上的元件以及调控细胞和调控激活基因环境的调控元件。涵盖的数据包括 ATAC-seq/ChIP-seq/eCLIP-seq/ChIA-PET/Hi-C 等。

作为行业内普遍认可的数据库，ATAC 结果的标准，ENCODE 上是这样写的：

ATAC 测序现成标准：

- 实验需两个或者两个以上的生物学重复。
- 每个文库至少 15 M 的比对 reads（单端测序模式）或者 50 M 的比对 reads（双端测序模式）。
- 比对率最好超过 95%，但是大于 80%也是可接受的。
- IDR 值评估重复样本的相关性。IDR 值需小于 2。
- 文库复杂度用 NRF 和 PBC1、PBC2 表示，标准 NRF>0.9, PBC1>0.9, PBC2>3。
- 文库峰型必须有核小体 free 的峰。
- FRIP 指需大于 0.3，但是大于 0.2 也是可接受的。
- Call peak 时，replicated peaks 模式，peak 数需要大于 15 万，大于 10 万也是可接受的。IDR peak 模式时，peak 数需要大约 7 万，大约 5 万也是可接受的。

2.6 ATAC 生信分析流程

ATAC-seq 和 CUT&Tag 生信分析流程有很多共通之处，因而两个实验的生信分析流程写到一起，方便大家使用。生信流程见本书最后的附件。

2.7 ATAC 实验问题解决指南

问题	可能的原因	建议
文库构建失败	实验过程中细胞核丢失	细胞核丢失：离心的时候将离心管的方向都调整为统一方向，弃上清时沿着沉淀的对面侧壁缓慢吸去，注意液体不要完全吸干。
测序结果背景噪音高	细胞活性低	用 DNase I 对细胞进行处理，可消化死细胞或者活性差的细胞释放出来的游离 DNA 或开放 DNA，降低背景噪音。
	实验过程中细胞核破裂	在处理细胞或者细胞核时，吹打要轻柔，可以用宽口枪头或者将枪头前端剪去 1cm 左右，不要剧烈涡旋振荡。实验中试剂尽量不要产生气泡，气泡破裂时会损伤细胞核，可能会导致最终的文库片段不呈典型的核小体分布。
线粒体 Reads 占比高	有些细胞裂解后，释放大量线粒体 DNA，未弃干净	可以用含有 0.1% Tween-20 的 wash buffer 漂洗细胞核。

第三章 CUT&Tag 技术简介、实验操作以及生信分析流程（含分析代码）

3.1 CUT&Tag 技术介绍

ChIP 替代新技术-CUT&Tag

表观遗传是指 DNA 序列不发生变化但基因表达却发生了可遗传的改变，即基因型未发生变化而表型却发生了改变。表观遗传调控是指基因的表达水平受各种修饰的影响，其分子基础有两个方面，即针对 DNA 本身的修饰和对组蛋白的修饰。蛋白质与 DNA 相互作用是基因转录调控的关键，也是基因转录启动的前提。

传统蛋白质 DNA 互作研究常用的有凝胶阻滞，酵母杂交，ChIP-Seq 等，其中 ChIP-Seq 可以完整的反映与靶蛋白结合的 DNA 序列，是蛋白质与 DNA 互作的经典方法。

但是近年来 CUT&Tag（Cleavage Under Targets and Tagment）作为一种新兴的 DNA 蛋白互作研究技术，凭借其信噪比高，可重复性好，实验周期更快等优势，在植物以及动物细胞中的成功应用，相关科研成果也陆续发表[1-2]，受到广大科研工作者的信赖。

The phosphatase PAC1 acts as a T cell suppressor and attenuates host antitumor immunity

Dan Lu, Liang Liu, Yizhe Sun, Jia Song, Qi Yin, Guangze Zhang, Fang Qi, Zixi Hu, [Zeliang Yang](#), Zhe Zhou, Ying Hu, Lianhai Zhang, Jiafu Ji, Xuyang Zhao, Yan Jin, Michael A. McNutt & Yuxin Yin 

Nature Immunology **21**, 287–297(2020) | [Cite this article](#)

11k Accesses | **43** Altmetric | [Metrics](#)

DNA 蛋白质互作研究进展

2009 年, Dominic Schmidt 等将 ChIP 与当时热门技术 NGS 结合, 发明了 ChIP-Seq 技术, 从而能够在全基因组范围内检测与蛋白相互作用的 DNA 区域。

1. ChIP-Seq

1) 实验原理: 甲醛处理细胞使目标蛋白与 DNA 交联, 通过超声波将交联后的染色质打断成小片段, 一般在 200-600 bp 范围内, 再利用抗原抗体的特异性识别反应, 将与目的蛋白相结合的 DNA 片段沉淀下来, 纯化之后进行文库的构建并测序。

2) 实验流程




图: ChIP-Seq 实验流程

3) 实验难点


- 时间长, 一次实验需要 2~3 天, 且操作误差对实验结果影响大;
- 为了消除背景的噪音, 起始的细胞需求量大, 需要 10⁷ 个细胞;
- 甲醛交联与免疫共沉淀需根据经验控制时间, 会造成非特异结合增加;
- 对抗体的特异性要求高, 需要 ChIP 级别的抗体。

2019 年, Henikoff 实验室发明了 CUT&Tag, 使用 ProteinA/G-Tn5 从而简化了二代测序的步骤, 并且极大降低了细胞的起始数量。

2. CUT&Tag


1) 实验原理: CUT&Tag 是蛋白质与 DNA 互作的革新技术, 无需通过甲醛交联以及免疫共沉淀, 其核心技

术为 pA/G-Tn5 Transposase，将 Protein A/G 与 Tn5 转座酶进行融合，使得与抗体结合的同时，Tn5 切割核小体上缠绕的 DNA 片段，获得目的序列。



图：CUT&Tag 原理图

2) 实验流程实验首先利用连有刀豆蛋白 A 的磁珠 (ConA) 结合细胞（主要原理是通过与细胞膜上的糖蛋白结合），同时利用洋地黄皂苷进行细胞膜通透，接着孵育靶蛋白的抗体，二抗以及 Protein A/G Tn5。抗体和 Protein A/G 与 Tn5 能够进入细胞核,Tn5 此时在 Protein A/G 的帮助下切割靶蛋白附近的 DNA 序列，由于 Tn5 是经过修饰的，切割的同时会在片段的两端加上一部分 Adapter 序列，再通过 PCR 文库扩增可得到对应的文库进行测序。




图：CUT&Tag 实验流程（实验时长缩短至 6 h）

3) 技术优势


- 操作简便：无需甲醛交联、超声打断、免疫共沉淀，无需补平，加 A 和接头；
- 特异性好：抗体与靶蛋白特异性结合进行目标区域定位；
- 起始量低：所需细胞数 10^7 下降到 10^2 ，甚至可以做单细胞水平研究；
- 性价比高：无需 ChIP 级别抗体，背景噪音低，所需测序深度少；
- 重复性好：实验重复结果一致性好。

Henikoff 等通过三种方法来对组蛋白 H3K27me3 进行研究，在相同的数据量（8M Reads）情况下，三种方法的染色体景观相似，但 ChIP-Seq 的背景较高，CUT&Tag 的信号更强，信噪比更高。



图：CUT&Tag、CUT&RUN（Henikoff 于 2017 年发明了新技术）的 peaks 鉴定结果与 ChIP-Seq 的对比(Henikoff,2019)

同时 CUT&Tag 可以对极少量细胞（60 个细胞）进行操作，实现单细胞测序。Protein A-Tn5 在细胞内进行核酸切割，PCR 之前的反应都在细胞内进行。Henikoff 博士通过分配单个细胞到 5184 纳米孔，再加入带随机标签的引物进行扩增的办法，实现单细胞测序。



图：单细胞 CUT&Tag 测序流程(Henikoff,2019)

参考文献：

1. Dan Lu, Liu L, Sun Y, Song J, Yin Q, Zhang G, Qi F, Hu Z, Yang Z, Zhou Z, Hu Y, Zhang L, Ji J, Zhao X, Jin Y, McNutt MA, Yin Y. The phosphatase PAC1 acts as a T cell suppressor and attenuates host antitumor immunity. Nat Immunol. 2020 Mar;21(3):287-297. doi: 10.1038/s41590-019-0577-9. Epub

2020 Jan 13. PMID: 31932812.

2. Tao X, Feng S, Zhao T, Guan X. Efficient chromatin profiling of H3K4me3 modification in cotton using CUT&Tag. Plant Methods. 2020 Aug 31;16:120. doi: 10.1186/s13007-020-00664-8. PMID: 32884577; PMCID: PMC7460760.

3. Kaya-Okur, H. S., Wu, S. J., Codomo, C. A., Pledger, E. S., Bryson, T. D., Henikoff, J. G., ... & Henikoff, S. (2019). CUT&Tag for efficient epigenomic profiling of small samples and single cells. Nature communications, 10(1), 1930.

3.2 多靶标 CUT&Tag 技术介绍

Nanobody-Tn5，赋予 CUT&Tag 不一样的体验

——一份样本，两种靶标，节省样本，节省时间

CUT&Tag 技术，作为研究蛋白质-DNA 互作的新兴技术，从问世之初，就一直备受关注。

Nanobody（纳米抗体）在药物抗体研究中的风很大，在医药领域备受青睐。那纳米抗体怎么就与 CUT&Tag 关联上了呢？

2022 年 12 月，Gonçalo Castelo-Branco 课题组和美国纽约基因组中心 Ivan Raimondi 团队同期在 Nature Biotechnology 上发表了关于 nanobody-Tn5 的文章。Nanobody-Tn5 主要是将纳米抗体与 Tn5 转座酶进行融合，制备出可结合两种不同物种（小鼠和兔）一抗的 anti-mouse Tn5 和 anti-rabbit Tn5。这两种 nanobody-Tn5 中包埋了含不同 index 的接头序列，Tn5 切割染色质时，接头插入到染色质中，通过不同的 index 来区分来源于 mouse 的一抗靶向区域还是来源于 rabbit 一抗靶向的区域。关于这两篇文章，Nature Biotechnology 杂志也给出了回应：这两篇论文的主要创新是在检测中使用纳米体，可以测量单个细胞中两种或更多组蛋白修饰的全基因组存在，以及细胞表面蛋白表达(NTT-seq)或染色质可及性(Nano-CT)。这种方法使我们能够在更高的水平上以高灵敏度和准确性观察复杂的单个细胞表观基因组研究。


2023 年 3 月，翌圣生物全球首发 Multi-CUT&Tag 试剂盒（CUT&Tag2for1 照进现实，Multi-CUT&Tag 试剂盒全球首发

<https://mp.weixin.qq.com/s/4gf2VlyJ5uY5Dwf8u7FGWg>），产学研合作，推出了利用 nanobody-Tn5（anti-rabbit tn5 和 anti-mouse tn5）组成的 Multi-CUT&Tag 标准化试剂盒，实现了一份样本，两种靶标的标准操作。

关于这个利用 nanobody-Tn5（anti-rabbit tn5 和 anti-mouse tn5）组成的 Multi-CUT&Tag 标准化试剂盒的性能大家也很期待吧，来，我们上一波数据吧！

1) H3K4me1

将 H3K4me1 使用常规的 CUT&Tag 试剂盒以及使用 nanobody-Tn5 的试剂盒进行单靶标和多靶标建库并上机测序，结果如下：




图：H3K4me1 使用常规 CUT&Tag 试剂盒和 Multi-CUT&Tag 试剂盒结果图

使用常规 CUT&Tag 试剂盒以及 Multi-CUT&Tag 试剂盒做单靶标实验时，结果差异不大，在某些位点上，Multi-CUT&Tag 信号更明显。Multi-CUT&Tag 做双靶标实验时，联合其他抗体（K3K27ac、H3K4me3、H3K36me3）均能拆分并且分析结果与单靶标结果一致。

2) H3K4me3

将 H3K4me3 使用常规的 CUT&Tag 试剂盒以及使用 nanobody-Tn5 的试剂盒进行单靶标和多靶标建库并上机测序，结果如下：




图：H3K4me3 使用常规 CUT&Tag 试剂盒和 Multi-CUT&Tag 试剂盒结果图

使用常规 CUT&Tag 试剂盒以及 Multi-CUT&Tag 试剂盒做单靶标实验时，结果差异不大。Multi-CUT&Tag 做双靶标实验时，联合其他抗体（K3K27me3、H3K4me1、H3K9me3、H3K9ac）均能拆分并且分析结果与单靶标结果一致。

3) H3K9me3

将 H3K9me3 使用常规的 CUT&Tag 试剂盒以及使用 nanobody-Tn5 的试剂盒进行单靶标和多靶标建库并上机测序，结果如下：




图：H3K9me3 使用常规 CUT&Tag 试剂盒和 Multi-CUT&Tag 试剂盒结果图

使用常规 CUT&Tag 试剂盒以及 Multi-CUT&Tag 试剂盒做单靶标实验时，结果差异不大，在某些位点上，Multi-CUT&Tag 信号

更明显。Multi-CUT&Tag 做双靶标实验时，联合其他抗体（K3K27ac、H3K4me3、H3K36me3）均能拆分并且分析结果与单靶标结果一致。

4) H3K27ac

将 H3K27ac 使用常规的 CUT&Tag 试剂盒以及使用 nanobody-Tn5 的试剂盒进行单靶标和多靶标建库并上机测序，结果如下：




图：H3K27ac 使用常规 CUT&Tag 试剂盒和 Multi-CUT&Tag 试剂盒结果图

使用常规 CUT&Tag 试剂盒以及 Multi-CUT&Tag 试剂盒做单靶标实验时，结果差异不大，在某些位点上，Multi-CUT&Tag 信号更明显。Multi-CUT&Tag 做双靶标实验时，联合其他抗体（K3K27me3、H3K4me1、H3K9me3、H3K9ac）均能拆分并且分析结果与单靶标结果一致。

5) H3K27me3

将 H3K27me3 使用常规的 CUT&Tag 试剂盒以及使用 nanobody-Tn5 的试剂盒进行单靶标和多靶标建库并上机测序，结果如下：




图：H3K27me3 使用常规 CUT&Tag 试剂盒和 Multi-CUT&Tag 试剂盒结果图

使用常规 CUT&Tag 试剂盒以及 Multi-CUT&Tag 试剂盒做单靶标实验时，结果差异不大。Multi-CUT&Tag 做双靶标实验时，联合其他抗体（K3K27ac、H3K4me3、H3K27ac、H3K36me3）均能拆分并且分析结果与单靶标结果一致。

6) H3K9ac

将 H3K9ac 使用常规的 CUT&Tag 试剂盒以及使用 nanobody-Tn5 的试剂盒进行单靶标和多靶标建库并上机测序，结果如下：



图：H3K9ac 使用常规 CUT&Tag 试剂盒和 Multi-CUT&Tag 试剂盒结果图

使用常规 CUT&Tag 试剂盒以及 Multi-CUT&Tag 试剂盒做单靶标实验时，结果差异不大，在某些位点上，Multi-CUT&Tag 信号更明显。Multi-CUT&Tag 做双靶标实验时，联合其他抗体（K3K27ac、H3K4me3、H3K36me3）均能拆分并且分析结果与单靶标结果一致。

3.3 CUT&Tag 实验操作（图文详解）

3.3.1 CUT&Tag 实验样本准备以及样本前处理

ATAC/CUT&Tag 实验前，需要准备样本。实验样本可以是新鲜细胞或者组织、新鲜植物组织或者冻存细胞/组织、冻存植物样本。不同样本的保存以及实验前样本量要求，见本书附录一。

样本准备完成后，需要对样本进行提核处理。提核实验的部分，ATAC 以及 CUT&Tag 实验都能够通用，因而该步骤放在本书最后，见本书附录二。

3.3.2 CUT&Tag 实验操作（图文详解实验操作）

CUT&Tag 试剂组分以及原理

组分编号			组分名称	原理
BOX-I	12592-A	⊖	ConA Beads	结合细胞/细胞核表面糖蛋白，用于细胞/细胞核磁珠捕获
	12592-B	○	DNA Extract Beads	小片段纯化和回收
	12592-C	○	DNA Selection Beads	文库纯化和分选
BOX-II	12592-D	●	10 × Binding Buffer	细胞捕获缓冲液
	12592-E	●	10 × Wash Buffer	细胞洗涤缓冲液
	12592-F	●	5% Digitonin	毛地黄皂苷，细胞/细胞核表面打孔
	12592-G	●	50 × PB Buffer	抗体结合缓冲液
	12592-H	●	10 × Dig-300 Buffer	转座酶结合缓冲液
	12592-I	●	Anti-mouse Tn5	偶联了鼠二抗的纳米 Tn5 复合物
	12592-J	●	Anti-rabbit Tn5	偶联了兔二抗的纳米 Tn5 复合物
	12592-K	●	33 × Activating Buffer	转座酶激活缓冲液
	12592-L	●	15 × Terminate Solution	转座酶活性抑制缓冲液
	12592-M	●	30 × Proteinase K	蛋白酶 K，消化蛋白
	12592-N	●	DNA Spike-in Mix (5 ng/μL)	内参

12592-O	⊖	2×HiFi Amplification Mix	高保真扩增酶，文库扩增使用
12592-P	○	i5 Universal Primer	I5 端 index
12592-Q	○	i7 Index Primer (T701)	I7 端 index


CUT&Tag 实验操作流程与时间

细胞捕获 (0.5 h) → 结合一抗/二抗 (2.5 h) → 结合转座酶 (1 h) → 转座酶激活 (1 h) → 蛋白酶 K 消化和基因组 DNA 回收 (1h) → 文库扩增 (1 h) → 文库分选与质检 (0.5~1h)

CUT&Tag 建库实验流程详解 (以多靶标 CUT&Tag 建库试剂盒 12592ES 为例)

① 自备材料

1. 抗体：靶蛋白的一抗（鼠源或者兔源）、蛋白酶抑制剂:推荐使用 InStab™ Protease Cocktail,EDTA-free,mini,tablet-form (Yeasen cat#20123) 或其他等效产品。
2. 文库质检：Agilent 2100 Bioanalyzer DNA 1000 Chip/ High Sensitivity Chip 或其他等效产品、文库定量试剂。
3. 其他材料：无水乙醇、无菌超纯水、低吸附枪头、PCR 管、磁力架、PCR 仪等。
4. 接头：Hieff NGS® Tagment Index Kit for Multi-CUT&Tag (Cat#12417) 。
- 5.CUT&Tag 建库试剂盒 (12592ES) 。



② 细胞收集


1. 在室温条件下收集细胞并计数，死亡的细胞染色质松散，暴露出大量的裸 DNA，转座酶复合物随机切割会造成比较强的噪音信号，建议样本细胞活性不低于 80% (细胞活性可以用台盼蓝染色来鉴定)。
2. 贴壁较紧的细胞如 Hela 细胞等可用 Accutase 或者 Trypsin 部分消化获得。
3. 植物或真菌细胞可通过特殊处理获得原生质体或细胞核进行实验，方法可参考附录。
4. 新鲜或者冻存的动物组织可通过特殊处理获得细胞/细胞核悬液进行实验，方法可参考附录。

③ 细胞捕获

1. 磁珠活化:

- 取一支 8 联管, 根据实验所需的样本数量, 每孔加入 100 μL **1 $\times$ Binding Buffer**。
- 使用移液器充分重悬 ConA Beads, 取出 10 μL ConA Beads 至步骤 a) 的 **1 $\times$ Binding Buffer** 中, 用移液器轻轻吹打均匀, 置于磁力架上, 待溶液澄清后, 弃上清。
- 将 8 联管从磁力架上取下, 加入 100 μL **1 $\times$ Binding Buffer**, 用移液器轻轻吹打混匀。
- 将 8 联管置于磁力架上, 待液体澄清后, 弃上清, 加入 10 μL **1 $\times$ Binding Buffer** 重悬 ConA Beads。

【注】: 若样本较多, 可在 EP 管中一起处理 ConA beads (10 倍于原磁珠体积的 **1 $\times$ Binding Buffer** 清洗磁珠), 在 4.2.3 活化后的磁珠与细胞结合步骤时再分装入 8 连管中即可。



2. 细胞准备:

- 在室温下收获细胞*并计数, 取 100-100,000 个细胞于 1.5 mL EP 管中, 室温 600 $\times$ g 离心 5 min, 弃净管内溶液;


【注】*: 收集的细胞在实验前, 建议用台盼蓝染色进行细胞活性鉴定, 细胞活性不低于 80%, 细胞活性过低, 容易导致背景噪音。

- 加入 500 μL **1 $\times$ Wash Buffer**, 轻轻吹打重悬, 室温 600 $\times$ g 离心 5 min, 弃净管内溶液;
- 加入 100 μL **1 $\times$ Wash Buffer**, 轻轻吹打重悬, 转移至 PCR 管中。

【注】: 1. 对于大小不同的细胞, 请根据实际情况调整离心力;

2. 可选步骤-获取细胞核;

3. 对于一次实验需要较多细胞, 可在一管 EP 管中收集, 用 **1 $\times$ wash buffer** 一起重悬, 到步骤 4.2.3 活化后的磁珠与细胞结合步骤时再分装即可。



3. 活化后的磁珠与细胞结合：

a) 将 100 μ L 细胞（细胞核）转移至含有活化 ConA beads 的 8 联管中，上下颠倒（轻柔）混匀后，瞬时离心 ($<100 \times g$)，室温水平旋转孵育 10 min（亦可室温桌面放置 10 min，期间颠倒混匀 2-3 次）。

【注】：1. 离心管需低吸附。

2. 旋转孵育转速根据仪器情况调整，保持管中液体能轻微晃动即可，避免试剂碰到管盖。


3. 请提前准备好下一步骤所需的预冷 Primary Antibody Buffer。

b) 瞬时离心 ($<100 \times g$)，将 8 联管置于磁力架上，待溶液澄清后（约 2 min），弃上清后取下 8 联管，立即进入步骤 4.3 结合一抗和转座酶（请提前准备好 Primary Antibody Buffer）。

【注】：1. 结合细胞后的磁珠需要轻柔操作，避免剧烈涡旋导致细胞损伤。建议颠倒、轻弹底部或者用平口枪头轻轻吹吸等方式混匀，避免产生大量气泡，避免磁珠在磁力架上放置过长时间和直接暴露在空气中时间过长（不超过 3 min）造成磁珠结块及细胞破裂。

2. 孵育过程中出现部分磁珠沾壁/聚集是正常现象，只要保证磁珠-细胞复合物处于溶液浸润的范围内，并不会影响后续的实验结果。

3. 接下来的实验涉及多步上下颠倒混匀步骤，需轻柔，如果磁珠聚集在底部，可以倒置轻轻拨动管底，使其混匀。



④结合一抗和转座酶


【注】*：本试剂盒的一抗只能是鼠源或者兔源，在做双靶标研究时，一抗需一支来源于鼠，一支来源于兔。若做单靶标实验时，步骤5中，1 $\times$ Dig-300 Buffer 加入 98 μ L，一抗使用鼠源一抗，则需使用 2 μ L Anti-mouse Tn5，若一抗使用兔源一抗，则需使用 2 μ L Anti-rabbit Tn5。

1. 每个样本加入 50 μ L 预冷的 **Primary Antibody Buffer** 重悬细胞(细胞核)-磁珠复合物。
2. 参照抗体说明书推荐的浓度向 8 联管中加入抗体（若不确定抗体的加入量，可先加入 0.5 μ L 抗体看看情况，如果实验时，加入两种抗体，则每种抗体各加 0.5 μ L），上下颠倒混匀。

【注】：本实验无需加入二抗，且本试剂盒不建议设置阴性对照。

3. 瞬时离心(<100 $\times$ g)收集液体于管底（切忌因离心时间过长，导致磁珠聚集在管底），室温下旋转孵育 2 h 或者 4 $^{\circ}$ C 旋转孵育过夜，最好水平旋转，保证液体在管底。每隔 30 min 可轻弹底部混匀，避免磁珠聚集干结。
4. 将与一抗结合好的磁珠取下，瞬时离心(< 100 $\times$ g)，静置于磁力架至磁珠贴壁上，待溶液澄清(约 2 min)，弃净管内溶液。

注：为了降低非特异影响，一抗孵育完后，推荐使用 1 $\times$ wash buffer 进行清洗 3 次，再进行步骤 5 实验。




5. 将 8 联管从磁力架上取下，加入 96 μL **1 $\times$ Dig-300 Buffer** 后，再加入 2 μL Anti-mouse Tn5 和 2 μL Anti-rabbit Tn5（两种 Transposome 的浓度都为 0.17 mg/mL），用移液器吹打或上下颠倒数次混匀（若样品较多，Transposome 结合液可一起提前配制）。

【注】：*不同的实验环境，转座酶的切割活性可能不同，请根据实际情况，在此基础上调整转座酶的使用浓度。

若做单靶标实验，则此步骤修正为：加入 98 μL **1 $\times$ Dig-300 Buffer 后，再加入 2 μL Anti-mouse Tn5 或 2 μL Anti-rabbit Tn5（根据使用一抗为鼠源或者兔源进行选择），用移液器吹打或轻轻点动涡旋混匀 10 次。

6. 室温下旋转孵育 1 hour，最好水平旋转，保证液体在管底。每隔 30 min 轻弹底部混匀，避免磁珠聚集干结。



【注】：转座酶孵育可能会导致轻微的磁珠板结。孵育太久（超过 3 h）会造成转座酶非特异性结合到 DNA 上，增强了背景噪音。

7. 瞬离 ($<100 \times g$)，静置于磁力架至磁珠贴壁，待溶液澄清（约 2 min），弃净管内溶液，加入 200 μL **1 $\times$ Dig-300 Buffer**，轻轻点动涡旋或移液器吹打 10 次，充分分离磁珠及细胞。

8. 重复步骤 7 两次（共清洗磁珠 3 次）。

9. 立即进行步骤 4.4（转座酶激活）。

⑤转座酶激活

1. 提前 10 min 将 33 x Activating Buffer 室温解冻，混匀备用。

2. 配置 **1 $\times$ Activating Buffer**：取 48.5 μL **1 $\times$ Dig-300 Buffer**（见 Step4.1 中配制试剂）+ 1.5 μL **33 x Activating Buffer**，混匀。

3. 将 4.3.9 中的 8 联管瞬离 ($<100 \times g$) 后置于磁力架上，待液体澄清(约 2 min)后，弃上清。

4. 将 8 联管从磁力架上取下，每个样本加入 50 μL 步骤 2 中稀释的 **1 $\times$ Activating Buffer**，混合均匀。

5. 将 8 联管置于 PCR 仪中 37 $^{\circ}\text{C}$ 孵育 60 min 。


【注】：无需设置热盖，可使 PCR 仪保持开盖状态。



⑥蛋白酶 K 消化和基因组 DNA 回收

1. 向每个样品中加入 3.3 μL 15 $\times$ Terminate Solution、1 μL 浓度为 1 $\text{pg}/\mu\text{L}$ 的 DNA Spike-in mix V2(试剂盒中的浓度为 5 $\text{ng}/\mu\text{L}$) 和 1.7 μL 30 $\times$ Proteinase K (此时磁珠会板结) (若样品较多, 可一起提前配制)。全速涡旋样品约 10 sec, 混匀后瞬离, 将样品置于 PCR 仪, 55 $^{\circ}\text{C}$ 消化 30 min (热盖不低于 70 $^{\circ}\text{C}$)。
2. 短暂离心 ($<100 \times g$), 将 PCR 管置于磁力架上静置 5 min, 取 50 μL 上清。

【注】: 1. DNA Spike-in Mix 主要用于不同处理条件或者细胞状态下的测序数据 Normalization 和定量分析, 为非必需加入的组分。客户可根据实验需要判断是否加入 DNA Spike-in Mix。本试剂盒中提供的 DNA Spike-in 浓度为 5 $\text{ng}/\mu\text{L}$, 推荐添加量为 1 $\text{pg}/10$ 万, 根据实际细胞投入量将 DNA Spike-in 梯度稀释后添加, 也可根据靶蛋白的结合 DNA 能力和丰度自行调整 (DNA Spike-in Mix 需稀释后使用)。



3. 如果样本较多, 可将步骤 4.5.1 中 3.3 μL 15 $\times$ Terminate Solution, 1.7 μL 30 $\times$ Proteinase K 及 DNA spike-in Mix 配置预混液, 预混液应该在配置完 5 min 内使用, 不宜放置过久。

3. 加入 70 μL 室温下平衡的 DNA Extract Beads, 涡旋混匀或移液器吹打 10 次混匀, 室温静置孵育 5 min。
4. 短暂离心 ($<100 \times g$), 将 PCR 管置于磁力架上静置 3 min, 待磁珠完全贴壁后吸净管内溶液。
5. 保持 PCR 管始终处于磁力架上, 从另一侧加入 200 μL 80%乙醇, 避免直接冲刷磁珠, 静置 30-60 sec, 弃净管内溶液。
6. 保持 PCR 管始终处于磁力架上, 再次加入 200 μL 80%乙醇, 静置 30-60 sec, 弃净管内溶液。
7. 保持 PCR 管始终处于磁力架上, 开盖空气干燥至磁珠刚刚出现龟裂 (不超过 3 min)。

【注】: 1. 移除上清后, 可以短暂离心再置于磁力架上, 使用 10 μL 移液器将残留液体吸干净, 缩短干燥时间。

2. 避免磁珠过分干燥 (龟裂) 而降低回收效率。

8. 从磁力架上取下 PCR 管, 加入 23 μL ddH₂O, 并充分涡旋, 室温静置 5 min。
9. 将 PCR 管短暂离心, 置于磁力架上分离磁珠和液体, 待溶液澄清后 (约 5 min), 小心转移 21 μL 上

清至新的 EP 管中，继续进行步骤 4.6 文库扩增步骤或者放置于-20℃冰箱保存。



⑦文库扩增

1. 将表 1 中试剂解冻后颠倒混匀，瞬离后置于冰上备用。
2. 于无菌 PCR 管中配制表 1 所示反应体系。

表 1 PCR 扩增反应体系

名称	体积 (μL)
步骤 4.5 纯化产物	21
i5 Universal Primer	2
i7 Index Primer (T7XX)	2
2×HiFi Amplification Mix	25
ddH ₂ O	Up to 50 μL

【注】：*Hieff NGS® Tagment Index Kit for Multi-CUT&Tag (Cat#12417) 中提供 i5 Universal Primer 和多种 i7 Index Primer (T7XX)，可根据样品数量和 Index 选择策略自行选择。

3. 使用移液器轻轻吹打或振荡混匀，并短暂离心将反应液收集至管底。
4. 将 PCR 管置于 PCR 仪中，设置表 2 所示反应程序，进行 PCR 扩增。

表 2 PCR 扩增反应程序

温度	时间	循环数
热盖 105℃	On	
72℃	3 min*	—
95℃	3 min	—
98℃	10 sec	n cycles**
60℃	15 sec	
72℃	1 min	—
4℃	Hold	—


【注】：*此步不可省略。转座反应产物并非完整的双链 DNA，72℃孵育 3 min 用于生成成熟的 PCR 模板。

**由于不同靶蛋白的表达量、DNA 结合能力差异较大。实验中需根据建库起始细胞量、蛋白类型、细胞类型和样本处理情况适当调整扩增循环数。

环数。

⑧文库纯化和质检

1. 将平衡至室温的 DNA Selection Beads 磁珠，振荡或上下颠倒混匀。
2. 吸取 100 μL ($2\times$) **DNA Selection Beads** 至步骤 4.6 的 PCR 反应产物中，涡旋混匀或用移液器吹打混匀 10 次，室温静置孵育 5 min。
2. 短暂离心 ($<100 \times g$)，将离心管置于磁力架上静置 3 min，待磁珠完全贴壁后吸净 PCR 管中溶液。
3. 保持 PCR 管始终处于磁力架上，从另一侧加入 200 μL 80%乙醇，避免直接冲刷磁珠，静置 30-60 sec，弃净上清。
4. 保持 PCR 管始终处于磁力架中，再次加入 200 μL 80%乙醇，静置 30-60 sec，弃净上清。
5. 保持 PCR 管始终处于磁力架中，开盖空气干燥至磁珠刚刚出现龟裂（不超过 3 min）。
6. 从磁力架上取下 PCR 管，加入 21 μL ddH₂O，并充分涡旋，室温静置 5 min。
7. 将 PCR 管短暂离心并置于磁力架上分离磁珠和液体，待溶液澄清后（约 5 min），小心转移 20 μL 上清至新的 EP 管中，于 -20℃ 保存。
8. 如需获得长度分布更集中的文库扩增产物，可使用胶回收或者磁珠分选的方式进行长度分选和纯化。文库大小可使用 Agilent 2100 Bioanalyzer、Qsep 或者凝胶电泳进行检测。



3.4 CUT&Tag 实验躲坑妙招

3.4.1 甲醛交联与否

在 CUT&Tag 实验开始前，我们需要确定实验方案。尤其是 CUT&Tag 属于原位实验，在最初时，大家都默认为 CUT&Tag 实验无需甲醛交联。但是随着 CUT&Tag 技术的发展，科学家们

发现有些目标蛋白质在研究时，轻微甲醛交联效果更好。之后，更多的研究表明，CUT&Tag 不同的研究蛋白，所需的实验条件也不一样。

做组蛋白修饰、强结合的转录因子（如 CTCF、RNA polII 等）无需甲醛交联。

而一些弱结合的转录因子或转录辅因子则需要甲醛交联，并且甲醛交联的强度也不一样。


常规的轻微甲醛交联条件为 0.1% 甲醛室温交联 2 min，之后用 1.25 M 甘氨酸终止交联。

3.4.2 样本制备（此步骤非常重要，较好的样本制备是实验成功的必备条件）


不同的样本，在实验前需要进行不同的处理。目前 CUT&Tag 的实验操作流程，是针对新鲜的细胞样本设计的。如果是冻存的样本，需要制备成细胞核悬液后，再进行实验。

样本的制备，不论是制备成细胞悬液还是制备成细胞核悬液，需要保证一个实验原则，就是：实验要快、细胞/细胞核完整。

细胞需要保证细胞活性在 80% 以上，细胞核需要保证细胞核完整性在 80% 以上。检测时，最好用台盼蓝然后后显微镜镜检观察细胞状态。荧光染料染色能确定细胞活性和细胞计数，但是对于细胞核，不能看到细胞核完整性（细胞核边缘完整）。



图：细胞活性大于 80%（客户提供）



图：细胞核完整性大于 80%（翌圣拍摄）

3.4.3 抗体选择

实验中所用一抗在进行选择时，抗体级别优先顺序为：CUT&tag/CUT&RUN>ChIP > IP > IF > WB。

目前商业抗体或者自制抗体，同一抗并不能适用于所有物种。因为，在实验时，尽量选择文献已报道的在拟研究物种中成功实验的抗体。

目前搜索抗体，可以在一些抗体搜索引擎上进行筛选。小编在这里推荐几个好用的抗体搜索引擎供大家选择：CiteAb (<https://www.citeab.com/>) —世界最大的抗体搜索引擎、Antibody Validation Database (<http://compbio.med.harvard.edu/antibodies/>) —专业、简单以及 Biocompare (<http://www.biocompare.com/>) —公司和分类一目了然！

除了一抗的选择外，二抗的选择也是有要求的。首先，需要选择与一抗种属对应的二抗，如一抗来源于小鼠，二抗则需要选择抗鼠的二抗（羊抗鼠、驴抗鼠都行，只需要为抗鼠的二抗，不需要计较来源）；其次，CUT&Tag 实验中使用的二抗，最好不携带耦联标记（HRP、FITC 等）；最后，在选择了特殊亚型如 IgG1、IgG γ 等的一抗时，需要选择与一抗对应亚型的二抗，同时需要注意该亚型是否能被 protein A/G 识别。

注：使用多靶标 CUT&Tag 试剂盒或者使用 nanobody-Tn5 时，无需使用二抗。同时，实验时，可以不应设置阴性对照。

抗体孵育时，推荐过夜孵育。

物种	抗体亚型	Protein A(Cat#12597)	Protein A/G(Cat#12598)
Human	Total IgG	+++++	+++++
	IgG1	+++++	+++++
	IgG2	+++++	+++++
	IgG3	++	+++++
	IgG4	+++++	+++++
	IgM	++	++
	IgA1	++	++
	IgA2	++	++
Mouse	Total IgG	+++++	+++++
	IgM	-	-
	IgG1	++	++++
	IgG2a	+++++	+++++
	IgG2b	+++++	+++++
	IgG3	+++++	+++++
Rat	Total IgG	++	++++
	IgG1	+	+++
	IgG2a	-	+++++
	IgG2b	-	+++
	IgG2c	+++++	+++++
	IgG3	++	++++
Rabbit	Total IgG	+++++	+++++
Goat	Total IgG	++	+++++
Sheep	Total IgG	++	+++++
Guinea pig	Total IgG	+++++	+++++
Hamster	Total IgG	++	+++
Donkey	Total IgG	+++	+++++
Pig	Total IgG	+++++	+++++
Dog	Total IgG	+++++	+++++
Cat	Total IgG	+++++	+++++
Cow	Total IgG	++	+++++
Horse	Total IgG	++	+++++
Monkey	Total IgG	+++++	+++++

3.4.4 样本捕获

CUT&Tag 实验，主要是利用 ConA beads 来捕获细胞。ConA 主要目的是识别细胞/细胞核表面糖蛋白。大多数真核生物的细胞/细胞核能够被 ConA 结合，但是，在实验过程中，可能由于 buffer、pH 等变化，导致 ConA 结合效率低。在实验中，若实验结果发现捕获的细胞较少，可以在显微镜下镜检观察 ConA 结合细胞/细胞核的情况。目前 CUT&Tag 试剂盒中，ConA beads 大多直径为 1 μm ，而细胞/细胞核直径远大于 ConA beads。在显微镜

下，会看到同一个细胞结合多个 ConA beads 的情况。若发现游离的细胞较多，需要排查 ConA beads 结合细胞的步骤。

另外，ConA beads 在孵育过程中，需要保持 beads 悬于 buffer 的状态。在旋转孵育时，若发生磁珠干结，很有可能影响实验结果，因而建议 PCR 管水平旋转而非颠倒混匀。若实验室无水平旋转孵育条件，可将 PCR 管保持直立状态置于水平摇床上孵育。

3.4.5 gDNA 纯化

CUT&Tag 实验中，抗体靶向后，样本被 Terminate Solution 裂解，之后蛋白酶 K 消化后，剩下的为样本的 gDNA。此步骤得到的 DNA 纯化后，浓度较高，但是只有通过 PCR 扩增，才能得到目的蛋白真正结合的 DNA。

对于做 CUT&Tag-qPCR 实验验证时，推荐 PCR 扩增后再进行 qPCR 验证。


3.4.6 spike in 添加

CUT&Tag 实验中，建议添加 spike in。Spike in 作为外源添加的校正物，主要是为了校正因取样或者实验原因等引起的 DNA 靶向结合的误差。

在实验时，不同实验组投入等量的 spike in mix，因富集效率的差异，不同实验组中 spike in 的占比不一致，但是 spike in 投入量恒量，因而可以通过 spike in 来校正富集得到的 DNA。

3.4.7 文库库检

CUT&Tag 实验时，得到的文库会呈现特征分布，尤其是组蛋白修饰，会呈现特征的核小体分布，即呈现一个核小体、两个核小体、三个核小体等大小分布。在用安捷伦 2100 或者 Qseq 仪器检测时，文库片段小大呈现的分布为 340 bp 左右、540 bp 左右、740 bp 左右等片段集中的峰。




图：组蛋白修饰的特征峰

当然，特征峰通常只是在组蛋白修饰时会出现。在研究转录因子时，特征峰不是必须出现。原因是转录因子通常结合在染色质的开放区域，即核小体与核小体的连接区，在连接区，如果转录因子结合了 DNA，那么该位置不会被 Tn5 切割，而核小体区域因为组蛋白结合了 DNA，占据了 DNA 的切割位点，因而转录因子通常不一定出现核小体的特征峰。


3.5 CUT&Tag 相关衍生技术分享

衍生技术一：CoBATCH 和 uCoTarget：微孔中实现单细胞 CUT&Tag 研究

2019 年北京大学分子医学研究所、北京大学-清华大学生命科学联合中心研究员何爱彬研究团队利用组合条形码和靶向染色质释放技术，开发了一种名为“CoBATCH”的新型单细胞 ChIP-seq 技术。CoBATCH 技术具备普适性、易操作、高通量和高质量等优点，不仅可以捕获体外培养单细胞中染色质结合蛋白在基因组上的分布信息，还可用于分析组蛋白修饰研究。




图：融合蛋白 Protein A-Tn5 (PAT)：通过富集基因组区域的特异性抗体并与 Tn5 转座酶融合，得到融合蛋白 Protein A-Tn5 (PAT)。PAT 蛋白能够与细胞中的特定抗体结合，识别特定的基因序列并进行切割，进而连接接头序列，获得的 DNA 片段可直接进行 PCR 反应和文库制备。



图：CoBATCH 技术：CoBATCH 同样使用 Protein A-Tn5 (PAT)，并通过组合标签将带有不同 barcode 序列的 PAT 对分配到不同孔中的细胞内 DNA 进行转座，使细胞带上第一轮标签，然后将所有细胞合并，重新分配到不同的细胞孔中，再用不同的 PCR 引物扩增使细胞带上第二轮标签，从而实现一次数百个单细胞的目标蛋白结合位点检测。

2024 年，何爱彬研究团队于 Science Advances 期刊发表了题为 “Single-cell joint profiling of multiple epigenetic proteins and gene transcription” 的文章，报道了一种名为 uCoTarget (ultra-high throughput Combined TAGmenting enRichment for multiple epiGeneTic proteins in the same cells) 的单细胞多维表观检测新技术，能够在单个细胞同时捕获高达 5 种不同的蛋白质-染色质互作信息。




图：uCoTarget 实验流程：抗体和 PAT 简单孵育后的复合物依次切割逆转录-链置换之后的细胞。共通过 4 轮组合标签区分单细胞。

衍生技术二：NTT-seq/Nano-CT：基于 nanobody-Tn5 靶向切割

Gonalo Castelo-Branco 课题组和美国纽约基因组中心 Ivan Raimondi 团队同期在 2022 年 12 月份在 Nature Biotechnology 上发表了关于 nanobody-Tn5 的文章。

Nanobody-Tn5 主要是将纳米抗体与 Tn5 转座酶进行融合，制备出可结合两种不同物种（小鼠和兔）一抗的 anti-mouse Tn5 和 anti-rabbit Tn5。这两种 nanobody-Tn5 中包埋了含不同 index 的接头序列，Tn5 切割染色质时，接头插入到染色质中，通过不同的 index 来区分来源于 mouse 的一抗靶向区域还是来源于 rabbit 一抗靶向的区域。关于这两篇文章，Nature Biotechnology 杂志也给出了回应：这两篇论文的主要创新是在检测中使用纳米抗体，可以测量单个细胞中两种或更多组蛋白修饰的全基因组存在，以及细胞表面蛋白表达 (NTT-seq)或染色质可及性(Nano-CT)。这种方法使我们能够在更高的水平上以高灵敏度和准确性观察复杂的单个细胞表观基因组研究。特异亲和不同种属（小鼠或兔）或相同种属不同亚型（IgG1 或 IgG2a）的 nanobody-Tn5 可被不同的抗体招募到染色质不同的位置靶向切割。通过 10x 微流控平台区分单细胞。



图：NTT-seq/Nano-CT 实验流程图

3.6 CUT&Tag 结果评估


CUT&Tag 文库峰型根据研究抗体的不同，呈现不同的峰型。

- 抗体为组蛋白修饰时，CUT&Tag 文库会呈现类似 marker 一样的特征峰；
- 抗体为泛调控转录因子如 CTCF、polII 这样的，CUT&Tag 文库也会呈现类型 marker


一样的特征峰。

- 抗体为其他转录因子或者辅因子时，CUT&Tag 文库呈现的峰型没有明显特征，需要根据实验室研究对象的不同自行总结和判断。


翌圣 CUT&tag 试剂盒，已经成功在不同的样本中以及不同的抗体中实验，下面展示一些客户的真实案例：




人外周血 (H3K4me1)




人肿瘤组织 (H3K4me1)




人肿瘤组织 (H3K27ac)




人肿瘤组织 (JUN)




桃果实 (H3K27ac)





HEK293 细胞 (GFP)



293T 细胞 (H3K27me3)





U251MG 细胞 (H3K27me3)



Hela S3 细胞 (RNA polymerase II)

小鼠肝 (H3K27me3)



HUH6 细胞 (β -Catenin)

A549 (BDR4)

在 CUT&tag 实验中, spike in 添加后, 会在文库中呈现出来, 大家如果碰到文库中有明显的 400 多 bp 大小的片段, 一定不要惊讶为什么 (spike in 3 长度 300 bp, 再加上测序接头 138 bp 左右, 大小就在 400 多 bp)




图: CUT&tag 实验阴性对照组 IgG 组 spike in 的文库峰

3.7 CUT&Tag 生信分析流程

ATAC-seq 和 CUT&Tag 生信分析流程有很多共通之处, 因而两个实验的生信分析流程写到一起, 方便大家使用。生信流程见本书最后的附件。

3.8 CUT&Tag 实验相关问题解决指南

Part I : 产品定位相关

Q1. 本产品是否适用于细菌等原核生物的蛋白核酸互作研究?

A1: 原核生物没有组蛋白, 且有细胞壁, 要做的话建议用 0.3% 的甲醛交联后破除细胞壁再去做, 理论上可行。

Q2. 请问这个实验能代替 ChIP 实验吗?

A2: 对, 完美代替 ChIP

Q3.这个可以用来筛选免疫受体所识别的病毒 DNA 区段吗？

A3: 如果定位在细胞核里面应该可以做，在细胞质里面可能会由于 Digitonin 透化细胞膜导致 DNA 片段丢失。建议客户可能先使用甲醛交联，防止 DNA 丢失，再尝试用本试剂盒建库。

Q4.植物转录因子做 cut &tag 有什么限制？我们有个转录因子做 ChIP 重复性很差，不知道做 CUT &tag 可不可行

A4: ChIP 实验不管是组蛋白修饰还是转录因子都存在重复性差、背景信号高的问题，CUT&tag 实验最大的优势就在于实验重复性好，实验背景信号低。目前已经报道了非常多的样本使用 CUT&Tag 技术成功的案例，植物样本实验室制备原生质体或者细胞核实验都行。

Part II：产品实验相关

Q5.在植物上融合什么标签比较合适呢？

A5: 这个需要看客户有什么标签抗体，成功率主要取决于抗体是否好用以及蛋白表达丰度。尽量选择已经测试做 CUT&tag 或者 CUT&RUN 的抗体或者已经有相关文章报道的抗体进行实验

Q6.回收 DNA 的磁珠有单卖的吗

A6:本试剂盒中 Box I 带有 DNA 回收磁珠，客户如需额外购买，本司可以提供 (Cat#12601)

Q7.已知的转录因子，做 CUT&tag 实验，是否可以不测序，直接 qPCR 检测目的基因呢？

A7: 可以，但 qPCR 必须在文库扩增之后做，我们的 spike-in 可以作为内参进行相对定量。

Q8.植物中怎么捕获细胞？

A8: 植物细胞在使用本试剂盒建库之前需要破除细胞壁或者直接提取细胞核，植物细胞核提取方法可咨询翌圣生物，我们有完整的植物细胞核提取方案。

Q9.对抗体的要求如何

A9: 抗体一般按质量标准分为免疫荧光级别、western blot 级别、免疫共沉淀 (IP) 级别和染色质免疫共沉淀 (ChIP) 级别，CUT&tag 或 CUT&RUN 级别，本试剂盒要求的抗体尽量使用更高级别的抗体。

Q10.回收 DNA 的磁珠可不可以用于做 ChIP 里面的回收 DNA 步骤？

A10: 可用回收，但是 ChIP 实验一般捕获下来的 DNA 太少，而且体积较大，利用磁珠回收可能会有损失。建议酚氯仿抽提后沉淀，损失会小一些。

Q11.这个实验怎么做重复？平行重复还是独立重复？

A11: NGS 数据一般是两到三次平行重复。

Q12.想请问一下之前已经甲醛交联过的细胞 还可以做 CUT&tag 吗？

A12: 甲醛交联的细胞可以继续做，但甲醛浓度过高交联时，后续需要增加解交联步骤。

Q13.conA 磁珠用完了，其他组分还有，conA 磁珠有单卖吗？或者有替代品吗？

A13: ConA 磁珠暂不单卖

Q14.spike in mix 具体的作用是怎样的呢？

A14: spike in 主要用于对给实验数据定量提供依据，类似于内参的作用，可以看我们的 PPT 上有展示。对于不知道靶位点的目标蛋白或者处理条件会造成细胞内目标蛋白与 DNA 结合能力大幅度改变的情况，spike in 能够帮助做出更准确的定量，反映这些情况造成的实验假

阴性现象。此外，我们的 spike in 可以用于对目标 DNA 片段进行绝对定量，保证文章数据的准确性。

Q15.是不是需要先构建标签载体，转入原生质体再做后续的？还是用转基因植株做？

A15：原生质体可以直接用本试剂盒进行实验，植株要先提取细胞核，详情同问题 5。若有植物靶蛋白对应的抗体，可直接实验，若无对应抗体，需要构建转基因植株后使用标签抗体实验。

可以。

Q16. 请问有做过杨树的吗？

A16：目前内部暂未有专门针对杨树物种测试，但理论上是可行的。

Q17.测序数据中的背景噪音，主要指的哪一块，不同的样本有相对的参考么，还是越低越好？

A17：背景噪音主要来源于抗体的非特异性结合，可以根据文库分布情况以及生信分析的指标判断背景噪音。

Q18.转基因材料带有 flag 标签就可以直接做吗？

A18：可用直接做。

Q19.做 cut&tag 总是 duplicate 多该怎么优化呢

A19：可以适当提高细胞投入量和降低 PCR 循环数

Q20.之前做 western flag 标签有非特异条带，这样还能做吗？

A20：非特异性条带做 CUT&Tag 可能会产生非特异性的结合位点，建议客户更换抗体。如果非特异性条带不是 DNA 结合蛋白也可以试一下

Q21.IgG 对照也不用做吗？

A21：建议做的时候带一个 IgG 对照来评判结合特异性。

Q22. 细胞捕获后直接破膜加抗体，后续的孵育切割需要几个小时的时间，这时细胞内的转录因子的结合会不会产生变化？理论上说，转录因子对外界信号刺激很敏感。

A22：我们使用的缓冲液都是贴近细胞真实状态的缓冲液，影响会比较小。当然，如果担心自己的靶蛋白和一个结合较弱的转录因子在建库过程中与 DNA 解离了，可以用 0.2%的甲醛轻微交联一下。

Q23. IgG 和不加一抗都是背景很高

A23：很有可能是实验过程中，pAG-Tn5 与抗体偶联步骤出现问题，导致 tn5 酶非特异性切割。

Q24.请问打孔之后细胞是否已经失活，与 DNA 结合的蛋白质是否不在脱落？

A24：实验过程中会添加 digitonin 进行细胞打孔，主要作用是为了使抗体以及 pAG-tn5 等大分子进入细胞核内进行抗体靶向识别及酶切，不会使细胞失活。

Q25. CUT&tag 做组蛋白修饰用的都是通用抗体吗？会不会对物种有选择

A25：抗体并非都是通用抗体，同一支抗体并非能识别所有物种，所以实验时，需要根据自己的样本类型进行测试实验，选取更适合自己样本的抗体。

Q26. 二抗的选择有特殊的要求吗？

A26：首先，二抗需要选择与一抗来源对应，如一抗为兔源抗体，二抗需选择抗兔的二抗，

另外，建议选择含抗体重链和轻链的二抗，并且尽量不要偶联其他标记物如 HRP、FITC 等。

Q27. 贴壁细胞实验准备时，能使用胰酶消化么？

A27: 我们比较建议使用胰酶消化，虽然有地方报道使用胰酶会破坏细胞表面糖蛋白从而破坏细胞与 ConA 的结合，但是使用细胞刮进行刮取时，很容易压迫甚至裂解细胞，造成后续的一些实验背景干扰。

PartIII：产品技术相关

Q28.CUT&Tag 一般适用于哪些类型蛋白质的研究？能否应用于异染色质上的位点？

A28: 与 ChIP-seq 相同，CUT&Tag 主要用于分析全基因组范围内的 DNA-蛋白质结合位点分析和组蛋白修饰研究，包括存在于异染色质区域的蛋白，如存在于染色质压缩缠绕区的 H3K27me3。当用于研究转录因子时，转录因子的丰度较低会导致其文库产量也相比组蛋白修饰研究的文库产量低，但同样可以获得好的测序及数据分析结果。

Q29.CUT&Tag 适用的细胞类型有哪些？

A29: 1) 常见哺乳动物细胞 CUT&Tag 在常见哺乳动物细胞系上的应用比较成熟，常见的悬浮细胞系（如 K562）正常离心收集弃去培养基即可使用。对于大部分贴壁细胞系来说，可按照常规流程使用胰蛋白酶消化后得到细胞悬液后可正常进行 CUT&Tag 实验。需要注意的是，消化后的细胞由于表面糖蛋白减少，与 ConA 磁珠的结合能力有所下降，可能会损失 10-20% 的细胞。建议可采用刮下的办法得到悬浮细胞。另外理论上，CUT&Tag 可以在贴壁细胞中直接使用。ConA 磁珠的主要作用是方便换液并保持细胞呈分散状态，鉴于 CUT&Tag 基本逻辑类似于胞内流式或免疫荧光，因此可以参考免疫荧光的操作路线，用贴壁较牢固的细胞或适度固定的细胞尝试 CUT&Tag 实验。

2) 植物及其他细胞 可采用温和的方式制备原生质体或者提取细胞核进行实验。需要注意的是，细胞核与 ConA 磁珠的结合率为~50-80%，完整细胞与 ConA 磁珠的结合率>90%。另外理论上，植物细胞按照免疫荧光进行染色方案可以直接调整到 CUT&Tag 实验，其他物种逻辑上类似。

Q30.在准备实验细胞样品时，对细胞的状态有什么具体要求？

A30: 准备实验细胞样品时，对细胞的状态有什么具体要求？在准备细胞时需要保证细胞处于正常的生长状态，生长状态不佳的细胞，其胞内的蛋白核酸结合相互作用状况会发生改变，而死亡细胞的目的蛋白可能从染色质上的脱离，甚至细胞和染色质的破碎降解，严重影响实验结果。可以在准备细胞样品时用台盼蓝染色来鉴定细胞活性，细胞形态正常且样品活细胞占 >90% 即可。对于冻存的样本，相对于 LN2 快速冻存的样本，更加倾向使用“Mr. Frosty”缓慢冻存的样本。冰冻切片理论上可以直接在切片上进行 CUT&Tag 实验；事先甲醛固定的石蜡切片也有可能直接进行 CUT&Tag 研究。操作时按照免疫荧光的操作方式进行。

Q31.如何选择用于 CUT&Tag 的抗体？

A31: 一抗建议使用 ChIP 级别的抗体；对于二抗，则选择与 proteinA/G 亲和力高的抗体（绝大部分物种都可以）。

Q32.在实验过程中，观测到磁珠有凝聚现象怎么办？

A32: 在孵育时间比较长，特别是 4°C 过夜的情况下，可能会出现部分磁珠在溶液内凝聚。

一般情况下只要大部分磁珠仍处于溶液浸润范围内，干结在溶液边缘和液面上方的磁珠比例不大，则仍然能够得到正常的实验结果，继续进行后续实验即可。尽管如此，仍需注意高转速离心或过长时间置于磁力架，以及磁珠脱离液相时间过长而造成磁珠干结可能会加剧磁珠的凝聚。在实验过程中应尽量避免此类操作，以免为实验结果带来不确定的影响。

Q33.对于实验流程中可选的温度条件和时间，如一抗孵育和细胞裂解消化的步骤，该如何进行选择？

A33：在一抗孵育步骤中，对于组蛋白修饰靶点，或者丰度较大的 DNA 结合蛋白靶点，如 RNA Pol II，在室温下孵育两小时已经完全足够。而对于丰度较低的转录因子则推荐 4°C 孵育过夜。在细胞裂解后加入 Proteinase K 消化的步骤中，55°C 1h 小时和 37°C 过夜并无特别大的区别。通常情况下 55°C 消化 1h 小时即可，较高的反应温度也有利于破坏胞内 DNase 的活性。

Q34.对于 DNA 扩增和建库相关的试剂，如引物和扩增酶，能否使用其他来源的同类试剂？

A34：不建议使用本试剂以外的试剂混搭进行实验。整个说明书的实验流程，包括 PCR 程序都是针对试剂盒内部所提供的试剂进行优化的，引入任何非本试剂盒的试剂都可能会导致实验的失败。

Q35.对于 CUT&Tag 的实验样本，二代测序上机应该如何选择？有何特殊的要求？

A35：推荐常规的双端 150-300bp 测序，如常见 HiSeq 系列。

Q36.对于已经完成的 CUT&Tag 的实验，如何检验实验结果？

A36：二代测序标准的样检方法：利用 Qubit 荧光计、安捷伦 2100 可以检定文库的产出和片段分布。合格的文库应该可见类似 ATAC-seq 的典型梯状条带分布，而文库的产量则会因为具体靶蛋白的丰度不同而不同。若已知靶点结合序列的相关信息，也可设计相应位点的 PCR 引物与 GAPDH 一类的内参位点对照，通过 qPCR 来确定目的靶点的富集程度。粗略的实验结果评估可以通过适当增加 PCR 循环数后利用琼脂糖电泳来确定实验是否成功。若同时进行了普通 IgG 替换目的抗体作为一抗的阴性对照组，则可以在电泳图上看到阳性组和阴性组不同的条带图形。过度的 PCR 会造成大量的 PCR depulication 而带来大量无效数据，因此也不可以用此类样本进行回收建库上机。测序数据可以用 deeptools 的 plotHeatmap 或 plotProfile 来判断富集效果。

Q37.CUT&Tag 目标片段富集的不够好是什么原因？如何改进？

A37 参考免疫荧光的经验，CUT&Tag 出现特异性不好的主要原因包括：二抗、转座体（加镁离子之前）洗涤不够充分；抗体特异性不好、抗体浓度太高等，建议确定所选抗体是否合适、增加抗体稀释度、增加洗涤次数来改善。

Q38.阳性对照结果很漂亮，但是目标抗体没有好的富集是为什么？

A38：1)一般遇到这种情况，首先需要确认抗体质量本身，请选择可靠的 ChIP 抗体，保证您的采购渠道可信。

2)除非有足够的证据，当使用自己免疫或定制的抗体时，请尽量不要选择多肽免疫的抗体做 CUT&Tag 实验。

3)不同转录因子与 DNA 结合强度不同，或者您的研究对象通过与其他蛋白形成复合物结合在特定的 DNA 片段上，必要时可以使用甲醛交联。弱结合的转录因子容易从目标 DNA 上脱

落，不完全是抗体质量的问题。

4)由于转录因子在可以结合的目标片段往往远少于组蛋白，PolII 等，打断后的 DNA 量较少回收效率低，建议适当增加细胞量。（由于 CUT&Tag 特异性很好，背景很低，研究转录因子时，电泳看不见的 DNA 量足够获得很漂亮的结果，由于 DNA 量少，上机时按照传统方法比较难通过测序公司质控，需要与测序公司特别沟通。

Q39.CUT&Tag 重复性如何？如何评估 CUT&Tag 数据重复性？

A39: 1)基本分析方法参考 ChIP-Seq，同一组样品做三组重复实验，采用 deeptools 做 plotCorrelation 分析。

2)相关分析可以直接使用 BAM 比对文件，或分析 peak 文件，注意两种不同的文件得到的相关性数值会有较大差异。

3)做相关性分析时，采用泊松分布（pearson）会得到更好的分析灵敏度，注意使用泊松分布时应去除特别多的 reads（--removeOutliers）。

4)一般来说，同一次实验相关性在 90%以上，不同条件的两次实验之间应大于 60%（见图）Person 分布，两次实验细胞数等有差别，BAM 文件组内相关性很好，组间 60—70%；峰相关性很好。

Q40.与 ChIP-Seq 不同，由于 CUT & Tag 背景很低，不需要做 input，数据分析时应注意哪些问题？

A40: CUT&Tag 贡献信息的主要为单核小体与无核小体片段，因此建议序列比对时尽量选择小片段如小于 700bp，在数据量足够时可以只采用 <350bp 的片段

附录一：ATAC/CUT&Tag 实验前样本准备

新鲜贴壁细胞	>40 万细胞，条件允许下可准备备份，细胞活性>90%
新鲜悬浮细胞	
冻存贴壁细胞	>40 万细胞，条件允许下可准备备份，复苏后细胞活性>85%
冻存悬浮细胞	

新鲜培养贴壁细胞（以 12 cm dish 为例）

- (1) 确认细胞培养状态良好，培养基中无污染。
- (2) 移液器吸去培养基，加入恢复室温的细胞培养级别的 1×PBS（不含 Mg²⁺和 Ca²⁺）清洗 2-3 次。
- (3) 吸去 1×PBS，加入适量胰酶（推荐无 EDTA 的胰酶），37℃细胞培养箱消化（客户可根据自己的细胞系的消化时间来），显微镜下细胞呈球状分散即可进行下一步。
- (4) 加入含血清的细胞培养基（如 12cm dish 可加 5mL），终止消化，并将细胞收集到离心管中，4℃ 300-500g 离心 5min（可根据细胞大小，以及正常实验操作，选择适合细胞的离心力），弃上清。
- (5) 加入 1×PBS（不含 Mg²⁺和 Ca²⁺）清洗 1-2 次，500g 离心 5 min，弃上清。
- (可选) 若细胞需要冻存，则配置冻存液：①1 mL 配制好的冻存液（80%完全培养+10%FBS+10%DMSO）（百分比指体积比）重悬细胞沉淀，按照建议送样量分装，移至冻存管（请提前配置细胞冻存液且置于冰上预冷，防止新配置的冻存液过热损伤细胞，待冻存液恢复室温后使用）；②将冻存管置于程序降温冻存盒，于-80℃冰箱梯度降温并暂时保存（请严格按照程序降温来操作，对细胞造成的损伤最小）。24 hour 后，请将程序降温盒中的细胞样本转移至液氮中保存。若没有程序降温冻存盒，建议使用人工传统降温方法：冻存管置于 4℃ 10 min→-20℃ 30 min→-80℃ 16-18 hour（或过夜，最长放置不超过一个月）→转移至液氮长期储存。
- (6) 加入 1mL 含血清的培养基重悬细胞，计数。

新鲜培养悬浮细胞（25 mL 摇瓶）

- (1) 确定细胞生长状态良好且无污染。
- (2) 进行细胞计数，每样本取 40 W 个细胞以上，细胞悬液 4℃ 500×g 离心 5 min，小心去上清，离心条件可根据细胞类型进行调整。
- (3) 加入 1 mL 1×PBS（体系中不可含 Mg²⁺和 Ca²⁺）重悬细胞沉淀，清洗一次，4℃ 500×g 离心 5 min，小心弃上清。
- (可选) 若细胞需要冻存，则配置冻存液：①1 mL 配制好的冻存液（80%完全培养+10%FBS+10%DMSO）（百分比指体积比）重悬细胞沉淀，按照建议送样量分装，移至冻存管（请提前配置细胞冻存液且置于冰上预冷，防止新配置的冻存液过热损伤细胞，待冻存液恢复室温后使用）；②将冻存管置于程序降温冻存盒，于-80℃冰箱梯度降温并暂时保存（请严格按照程序降温来操作，对细胞造成的损伤最小）。24 hour 后，请将程序降温盒中的细胞样本转移至液氮中保存。若没有程序降温冻存盒，建议使用人工传统降温方法：冻存

管置于 4°C 10 min→-20°C 30 min→-80°C 16-18 hour (或过夜, 最长放置不超过一个月) →转移至液氮长期储存。

(4) 用 1 mL 以上的培养基/血清重悬细胞沉淀, 计数。

动物组织 (黄豆粒大小即可)	常见组织类型 40 mg 心、肾、神经等组织类型 50 mg
植物组织	幼嫩的组织叶片 0.3 g 种子、根等特殊组织部位 0.5~1 g

动物组织

(1) 取新鲜组织, 立即剔除结缔和脂肪组织等杂质。

(2) 将组织转移至新离心管中, 用预冷的 PBS 溶液漂洗至将组织表面的残留血液冲洗干净。(肌肉组织不易清洗, 建议增加漂洗次数)。

(3) 将冲洗干净的组织样本取出并用无尘纸擦干水分, 若组织体积较大, 应在冰上将组织切成小块或薄片 (每份约 50 mg), 之后置于 2 mL 旋盖冻存管内, 准备标记样本名称, 剩余组织直接进行实验。

(可选) 若组织样本需要进行冻存保藏, 可将含样本的冻存管迅速置于液氮中冷冻 30-60 min, 短期实验 (1 个月内) 可至于-80°C冰箱保存, 若需要长期保藏, 建议直接在液氮中保藏。

植物组织

(1) 从植物体上取下新鲜组织, 后用清水将材料表面的灰尘或泥土冲洗干净, 吸干。

(2) 如果组织体积较大, 应在冰上将组织切成小块或薄片, 然后放入 2 mL 或更大体积的旋盖冻存管中, 每份>300 mg, 准备标记样本名称, 剩余样本直接进行实验。

(可选) 若组织样本需要进行冻存保藏, 可将含样本的冻存管迅速置于液氮中冷冻 30-60 min, 短期实验 (1 个月内) 可至于-80°C冰箱保存, 若需要长期保藏, 建议直接在液氮中保藏。

附录二：样本细胞核提取 (图文详解实验操作)

细胞样本提核

组织样本提核：

1.1 自备试剂

苯甲基磺酰氟(PMSF)：推荐使用 (YEASEN Cat#58076) 或其他等效产品；

二硫苏糖醇 (DTT)：推荐使用 (YEASEN Cat#20311) 或其他等效产品；

蛋白酶抑制剂：推荐使用 InStab™ Protease Inhibitor Cocktail for bacterial cell extracts, 100× Stock Solution 蛋白酶抑制剂 Cocktail, 100× 储液 (YEASEN Cat#20137) 或其他等效产品；

PBS (1×) 细胞培养级：推荐使用 (YEASEN Cat# 41403) 或其他等效产品。

Hank's 平衡盐溶液 (HBSS)：推荐使用 (YEASEN Cat# 60147) 或其他等效产品。

胶原酶：主要分为四种类型：胶原酶 I 型, II 型, III 型和 IV 型, 推荐使用 (YEASEN Cat# 40507; Cat# 40508; Cat# 40509; Cat# 40510) 或其他等效产品。

1.2 自备耗材:

组织匀浆器, 冷冻离心机, 70 μm 细胞筛、细胞计数仪, 台式显微镜, 台盼蓝。

2.1 溶液配置 (以下配置的体积为单个样本反应的用量, 若有多个样本同时实验, 需根据样本量修改配置体积, 本试剂配置量已考虑了试剂损耗, 多样本配置无需额外计算损耗)

1) 取出 4 x NIB、NPB-A、10mM PMSF (自备)、1M DTT (自备)、100x 蛋白酶抑制剂 (自备) 于**冰上放置**;

2) 1 x NIB: 2.25 mL /样本, 750 μL 4 x NIB + 6 μL 10 mM PMSF + 3 μL 1M DTT + 30 μL 100x 蛋白酶抑制剂, 加入 2211 μL ddH₂O, 混匀 (**推荐现配现用**)。

3) NPB-B: 500 μL /样本, 250 μL 1 x NIB + 375 μL NPB-A, 混匀 (**推荐现配现用**)。

4) 消化液: 1mL Hank's 平衡盐溶液 (HBSS) + X* μL 胶原酶 (100mg/mL)

【注】: 1、以上 buffer 建议现配现用, 请根据实际样本数量现配现用, 配制的 buffer 冰上放置。

2、PMSF、DTT 浓度如和说明书中的浓度不一致, 配制 1xNIB 时保证终浓度一致, 更改 H₂O 的体积即可。

3、不同组织用的胶原酶种类和胶原酶浓度会存在差异。

2.1 组织消化 (选做)

实验开始前, 请将离心机 4°C 预冷, 实验全程在冰上操作。

1、将新鲜或者冻存组织放在冰上解冻, 用 PBS 清洗干净。

2、将清洗干净的组织在 Hank's 平衡盐溶液 (HBSS) 中剪碎至 1-2mm, 放置含有 1mL 消化液的离心管中, 37°C 孵育 10min。

【注】: 不同组织消化时间会有差异。

3、立即将消化后的组织放置干净的 Hank's 平衡盐溶液 (HBSS) 清洗 1-2 遍, 然后进行组织裂解。

2.2 组织裂解

1) 在预冷的组织匀浆器中加入 1.5 mL 1 x NIB, 加入新鲜或冻存动物组织 (20 mg 左右), 冻存组织需冰上解冻 5min; 或者直接加入消化后的组织。

2) 匀浆, Loose 10 次, Tight 20 次。

【注】: 不同器材会存在差异, 保证组织能够被磨碎即可, 切勿用力过度。

3) 将步骤 2 中的匀浆液通过 70 μm 细胞筛去除碎片, 悬液转移至新的 1.5ml 离心管中。

4) 2000 g, 4°C 离心 5 min。

5) 小心去除上清, 加入 500 μL 1 x NIB 进行重悬。

6) 取 500 μL NPB-A 至新的 2.0 mL 离心管中, 再吸取 500 μL NPB-B 沿着管壁缓慢加入至 NPB-A 的上层, 接着再将步骤 5 中的 500 μL 悬液沿着管壁缓慢加入 NPB-B 的上层, 此时溶液分为三层。

7) 500 g, 4°C 离心 10 min。

8) 上层溶液与 NPB-B 之间的白色核带即为细胞核层 (如下图所示), 用 200 μL 移液枪取白色核带至新的离心管中, 加入 1mL 1 x PBS 溶液, 轻轻吹打混匀, 该溶液即为细胞核悬液。

【注】: 吸取白色核带层, 切勿吸取到杂质。

9) 取 10 μL 细胞核悬液进行荧光及台盼蓝染色, 用于细胞核计数及显微镜观察。

10) 立即进行后续实验。

附录三：ATAC/CUT&Tag 实验生信分析流程（附详细生信分析代码）

本书生信分析流程为基因课网站所述流程，对应网址如下：
http://ftp.genek.cn:8888/20231225_MjJjNTQ5/_book/。

若需要有视频学习内容，可自行联系基因课购买生信学习资料。

本生信分析流程，纯交流使用，无任何盈利行为。

生信分析前，需要安装的软件和数据有：

- ◆ Snakemake 和 PeakSnake
- ◆ Fastp
- ◆ bowtie2 或者 bwa bowtie2
- ◆ samtools
- ◆ deeptools
- ◆ Picard
- ◆ MACS3
- ◆ IDR
- ◆ ChIPseeker 或 UROPA
- ◆ featureCounts
- ◆ DiffBind
- ◆ IGV
- ◆ R 包
- ◆ 准备好对应物种的参考基因组以及注释文件
- ◆ 准备好测序下机原始数据

重要提醒：本书所述分析流程中，一些文件所处位置以及命名，根据个人习惯需要进行更改。文章没有强调，所以需要大家在借鉴流程过程中，自动判断以及更换文件名称和位置。

一、参考基因组的下载

任何涉及 NGS 技术的生信分析，参考基因组的选择与下载是非常重要的一环。同时，在网络上下载的数据分析结果，也需要关注该数据分析时选择的参考基因组和注释信息版本。不同的参考基因组和注释信息版本，可能会得到不同的实验结果。另外，老师在确定参考基因组分析项目的时候，一定要指明自己所用的参考基因组下载地址和版本，因为各个数据库会有各自的一套基因 ID，如果用错了参考基因组，由于基因 ID 的不对应会对后期结果的查看造成不必要的麻烦。


目前 NGS 数据分析所需的参考基因组信息通常包括基因组文件（genome.fa）、基因结构注释文件（gene annotation.GFF）以及蛋白注释文件（pep.fa）。目前常用的基因组数据库为 NCBI (<https://www.ncbi.nlm.nih.gov/>，基因组收录较为全面) 和 Ensembl (涵盖大量物种的参考基因组信息，不同的物种下载网站不同)。除此之外，还有 UCSC (<http://genome.ucsc.edu/cgi-bin/hgGateway>，主要收录一些模式动物的数据库，尤其是人和鼠)、JGI (<https://phytozome.jgi.doe.gov/pz/portal.html>，主要收录绿色植物基

因组的数据库) 以及一些拟南芥单一物种参考基因组网站 TAIR (<http://www.arabidopsis.org/>) 和 水稻 专有基因组网站 (<http://rice.plantbiology.msu.edu/>) 等。本例简单介绍 NCBI 和 Ensembl 网站参考基因组下载方式。

1.1 NCBI 上参考基因组下载

以人 (human, Homo sapiens) 参考基因组下载为例

(1) 打开 NCBI (<https://www.ncbi.nlm.nih.gov/>) , 在搜索栏里输入 Homo sapiens (或 human, 优选拉丁名), 左侧 All Databases 处选择 Genome, 点击 Search 或直接点击 <https://www.ncbi.nlm.nih.gov/datasets/genome/>, 在搜索栏中输入 Homo sapiens, 点击 Search。



(2) 在跳转的页面, 找到对应的注释文件复制链接地址或者直接点击进入下载页面。

基因组文件 (genome.fa)

Homo sapiens (human)
Reference genome: Homo sapiens (assembly GRCh38.p14)
Download sequences in FASTA format for **genome**, transcript, protein
Download genome annotation in GFF, GenBank or tabular format
BLAST against Homo sapiens genome, transcript, protein
All 1060 genomes for species:
Browse the list
Download sequence and annotation from RefSeq or GenBank
NEW Try NCBI Datasets - a new way to download genome sequence and annotation we're testing in NCBI Labs

Display Settings: Overview

Send to: ▾

Organism Overview : [Genome Assembly and Annotation report \[1060\]](#) : [Organelle Annotation Report \[28\]](#)

ID: 51



Homo sapiens (human)

Human genome projects have generated an unprecedented amount of knowledge about human genetics and health.

Lineage: Eukaryota[10116]; Metazoa[4727]; Chordata[2283]; Craniata[2260]; Vertebrata[2260]; Euteleostomi[2241]; Mammalia[675]; Eutheria[501]; Euarchontoglires[202]; Primates[82]; Haplorrhini[60]; Catarrhini[46]; Hominidae[6]; Homo[1]; Homo sapiens[1]

Study of the human condition such as genetic and infectious disease, the intersection between genetics and the environment, and population variation is supported by a wealth of genome-scale data. These data sets include: a) numerous sequenced genomes including several which have been assembled; b) studies that examine transcript and protein existence, [More...](#)

基因组基因注释文件 (gene annotation.GFF)

Homo sapiens (human)
 Reference genome: Homo sapiens (assembly GRCh38.p14)
 Download sequences in FASTA format for genome, transcript, protein
 Download genome annotation in **GFF**, GenBank or tabular format
 BLAST against Homo sapiens genome, transcript, protein
 All 1060 genomes for species:
 Browse the list
 Download sequence and annotation from RefSeq or GenBank
NEW Try NCBI Datasets - a new way to download genome sequence and annotation we're testing in NCBI Labs

Display Settings: Overview

Send to: ▼

Organism Overview ; Genome Assembly and Annotation report [1060] ; Organelle Annotation Report [28]

ID: 51



Homo sapiens (human)

Human genome projects have generated an unprecedented amount of knowledge about human genetics and health.

Lineage: Eukaryota[10116]; Metazoa[4727]; Chordata[2283]; Craniata[2260]; Vertebrata[2260]; Euteleostomi[2241]; Mammalia[675]; Eutheria[501]; Euarchontoglires[202]; Primates[82]; Haplorrhini[60]; Catarrhini[46]; Hominidae[6]; Homo[1]; Homo sapiens[1]

Study of the human condition such as genetic and infectious disease, the intersection between genetics and the environment, and population variation is supported by a wealth of genome-scale data. These data sets include: a) numerous sequenced genomes including several which have been assembled; b) studies that examine transcript and protein existence, [More...](#)

基因组蛋白注释文件 (pep.fa)

Homo sapiens (human)
 Reference genome: Homo sapiens (assembly GRCh38.p14)
 Download sequences in FASTA format for genome, transcript, **protein**
 Download genome annotation in GFF, GenBank or tabular format
 BLAST against Homo sapiens genome, transcript, protein
 All 1060 genomes for species:
 Browse the list
 Download sequence and annotation from RefSeq or GenBank
NEW Try NCBI Datasets - a new way to download genome sequence and annotation we're testing in NCBI Labs

Display Settings: Overview

Send to: ▼

Organism Overview ; Genome Assembly and Annotation report [1060] ; Organelle Annotation Report [28]

ID: 51



Homo sapiens (human)

Human genome projects have generated an unprecedented amount of knowledge about human genetics and health.

Lineage: Eukaryota[10116]; Metazoa[4727]; Chordata[2283]; Craniata[2260]; Vertebrata[2260]; Euteleostomi[2241]; Mammalia[675]; Eutheria[501]; Euarchontoglires[202]; Primates[82]; Haplorrhini[60]; Catarrhini[46]; Hominidae[6]; Homo[1]; Homo sapiens[1]

Study of the human condition such as genetic and infectious disease, the intersection between genetics and the environment, and population variation is supported by a wealth of genome-scale data. These data sets include: a) numerous sequenced genomes including several which have been assembled; b) studies that examine transcript and protein existence, [More...](#)

(3) 找到对应的文件后，点击文件名进入下载页面或者点击鼠标右键—复制链接。

The screenshot shows the NIH National Library of Medicine website. The main content area displays information for 'Homo sapiens (human)'. A red box highlights the download link for 'GCF_000001405.40_GRCh38.p14_genomic.gff.gz' with a file size of 17.6 KB/s - 1,200 KB/54.3 MB and a download time of 52 minutes.

图：直接点击，进入文件下载页面



图：点击鼠标右键，选择复制链接


4) 选择复制链接时，需在 linux 系统中，使用 wget+链接下载相关数据。

1.2 Ensembl 上参考基因组下载

Ensembl 网站不同的物种，网址不同，分别为动物 (<http://ensembl.org/index.html>)、植物 (<http://plants.ensembl.org/index.html>)、细菌 (<http://bacteria.ensembl.org/index.html>) 以及真菌 (<http://fungi.ensembl.org/index.html>)。

以人参考基因组为例

1) 打开动物参考基因组网站 <http://ensembl.org/index.html>



图：Ensembl 网站首页参考基因组文件下载区

动物基因组网站上，如果需要下载人、小鼠、斑马鱼和猪的参考基因组，直接点击就行，如果是其他物种，则点击 View full list of all species。此次小编以 Human 为例，点击 Human，进入跳转页面。



图：人参考基因组分析文件对应下载位置


很多物种的基因组版本可能有多个，不同的基因组版本，对应不同的测序项目或者不同的测序时间。不同参考基因组版本对应的基因组的注释文件及蛋白注释文件可能略有差异。在进行数据分析前，需要确认参考基因组版本，若需要对分析后的结果与其他来源下载的分析结果进行比对分析，需要确认下载的分析数据当时分析所选的参考基因组版本。



图：人参考基因组的不同版本号


2) 本例之后的说明都以 GRCh38 为例进行数据下载。

下载参考基因组文件时，点击 Download DNA sequence，会在跳转页面出现非常多的数据，通常选择下载 XX.toplevel.fa.gz 文件即为 genome.fa 文件，其他为 rm, sm 和分开染色体的文件，具体文件代表意义参见 README 文件。



图：README 内各文件代表意义解释

选择点击鼠标右键-复制链接或者鼠标直接点击对应文件进行下载。





图：直接点击，进入文件下载页面

3) 基因结构注释文件 (gene annotation.GFF) 以及蛋白注释文件 (pep.fa) 下载时，点击对应的地方进行文件下载

Index of /pub/release-107/fasta/homo_sapiens

Name	Last modified	Size	Description
Parent Directory	-	-	-
cdna/	2022-06-05 20:14	-	-
cds/	2022-06-05 20:14	-	-
dna/	2022-06-05 20:14	-	-
dna_index/	2022-06-05 20:15	-	-
ncrna/	2022-06-05 20:15	-	-
pep/	2022-06-05 20:15	-	-

图：pep.fa 文件下载

Index of /pub/release-107/gff3/homo_sapiens

Name	Last modified	Size	Description
Parent Directory	-	-	-
CHECKSUMS	2022-06-05 20:13	1.6K	-
Homo_sapiens.GRCh38.107.abinitio.gff3.gz	2022-06-04 12:24	6.2M	-
Homo_sapiens.GRCh38.107.chr.gff3.gz	2022-06-05 19:04	43M	-
Homo_sapiens.GRCh38.107.chr_patch_hapl_scaff.gff3.gz	2022-06-05 19:04	47M	-
Homo_sapiens.GRCh38.107.chromosome.1.gff3.gz	2022-06-04 12:24	4.0M	-
Homo_sapiens.GRCh38.107.chromosome.2.gff3.gz	2022-06-04 12:24	3.3M	-
Homo_sapiens.GRCh38.107.chromosome.3.gff3.gz	2022-06-04 12:24	2.7M	-
Homo_sapiens.GRCh38.107.chromosome.4.gff3.gz	2022-06-04 12:24	1.7M	-
Homo_sapiens.GRCh38.107.chromosome.5.gff3.gz	2022-06-04 12:24	2.0M	-
Homo_sapiens.GRCh38.107.chromosome.6.gff3.gz	2022-06-04 12:24	2.0M	-

图：gene annotation.GFF 文件下载

4) 选择复制链接时，需在 linux 系统中，使用 wget+链接下载相关数据。

二、测序数据过滤与质控

这里使用 fastp 对测序数据进行过滤和质控 (数据过滤软件比较多, Trimmomatic、

Fastqc、preseq 等都可以，可以自行使用数据的过滤软件）。

对于 ATAC-seq 实验，有效数据量 50 M。

对于 CUT&Tag 实验来说，有效数据量：

- ◆ 转录因子：10~20 M
- ◆ 组蛋白修饰：20~40 M

```
fastp -i \
raw_data/XX_R1.fastq.gz \
-I raw_data/XX_R2.fastq.gz \
-o clean_data/XX.R1.fastq.gz \
-O clean_data/XX.R2.fastq.gz \
--html clean_data/XX_fastp.html \
--json clean_data/XX_fastp.json \
--thread 1 \
--adapter_sequence CTGTCTCTTATACACATCTCCGAGCCCACGAGAC \
--adapter_sequence_r2 CTGTCTCTTATACACATCTGACGCTGCCGACGA \
--qualified_quality_phred 20 \
--length_required 50 \
1>logs/XX_fastp_quality_control.log 2>&1
```

#XX: raw_data 处一般是测序下机时样本名称，其余处可以根据自己需求自行命名，为避免弄错，一般与输入数据名称相同

多个样本的质控结果，使用 combine_fastp_report.R 进行整合

```
Rscript scripts/combine_fastp_report.R \
--input clean_data/XX_fastp.json \
clean_data/XX_fastp.json \
clean_data/Input_XX_rep1_fastp.json \
--output quality_control/ \
1>logs/combine_fastp_reports.log 2>&1
```

```
library(readr)
fastp_summary <- read_delim(".././quality_control/fastp_summary.tsv",
delim = "\t", escape_double = FALSE, trim_ws = TRUE)
```

或

```
fastp_summary = read.table(file =
".././quality_control/fastp_summary.tsv", header = T)
```

```
$ bamtools stats -in clean_bams/ZAT6_ABA_rep1_final.bam
```

```
*****
```

Stats for BAM file(s):

Total reads: 23763436

Mapped reads: 23763436 (100%)

Forward strand: 11877371 (49.9817%)

Reverse strand: 11886065 (50.0183%)

Failed QC: 0 (0%)

Duplicates: 0 (0%)

Paired-end reads: 0 (0%)

三、参考基因组比对

4.1 构建基因组 index (索引)

常见物种的 index 可以直接从 bowtie2 官网下载。

```
bowtie2-build --threads 1 ref/genome.fa ref/genome \
```

```
1>logs/bowtie2_build.log 2>&1
```

#genome.fa 是此处参考基因组文件名称，需要根据实际样本基因组名称来命名；ref/genome 也是自行名称的索引文件名，可根据个人习惯自行更改

3.2 基因组比对

3.2.1 ATAC 基因组比对流程

```
bowtie2 -p 1
```

```
-x ref/genome \
```

```
-1 clean_data/XX_rep1_R1.fastq.gz \
```

```
-2 clean_data/XX_rep1_R2.fastq.gz \
```

```
-S raw_bams/XX_rep1.sam \
```

```
--no-mixed
```

```
--no-discordant \
```

```
--maxins 1000 \
```

```
1>logs/XX_rep1_bowtie2_align.log 2>&1
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

◆ --maxins 最大插入片段长度，设置到 1000~2000

◆ --no-mixed --no-discordant ATAC-seq 一般是 PE 测序，设置这两个参数

3.2.2 CUT&Tag 基因组比对流程

```
bowtie2 -p 1 \
```

```
-x ref/genome \
```

```
-U clean_data/XX.fastq.gz \
```

```
-S raw_bams/XX.sam \
```

```
1>logs/XX_bowtie2_align.log 2>&1
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

3.3 排序并转换为 bam

```
samtools sort \
  -@ 1 \
  -o raw_bams/XX_sorted.bam \
  raw_bams/XX.sam \
  1>logs/XX_sort_bam.log \
  2>&1
```

```
samtools index raw_bams/XX_sorted.bam
```

#XX 表示此处可以根据自己需求自行命名

3.4 过滤及其他处理

通常的做法是使用 picard 标记 duplicates，然后使用 samtools 去除各种低质量比对。deeptools 包中的 alignmentSieve 能够一步完成这些操作，而且速度更快。

这一步过滤

- ◆ duplicates：经过比较与 Picard 结果差异很小
- ◆ 低质量比对：MAPQ 小于 20 或 30
- ◆ 未比对上的 reads：SAM flag 4
- ◆ supplementary alignment：SAM flag 2048
- ◆ 比对到黑名单区域的 reads：黑名单、线粒体、叶绿体、大肠杆菌等

```
alignmentSieve \
  --numberOfProcessors 1 \
  --bam raw_bams/XX_sorted.bam \
  --outFile clean_bams/XX_final.bam \
  --filterMetrics logs/XX_sieve_alignment.log \
  --ignoreDuplicates \
  --minMappingQuality 25 \
  --samFlagExclude 260 \
  --blackListFileName ref/blacklist.bed \
  1>logs/XX_sieve_alignment.log
  2>&1
```

```
samtools index clean_bams/XX_final.bam
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

每个步骤中过滤掉了多少 reads 可以使用 deeptools 中的 estimateReadFiltering 进行估计。

```
estimateReadFiltering \
```

```
--numberOfProcessors 1 \
--bam \ raw_bams/XX_sorted.bam \
--sampleLabels XX \
--outFile quality_control/estimate_read_filtering.tsv \
--ignoreDuplicates \
--minMappingQuality 25 \
--samFlagExclude 260 \
--blackListFileName ref/blacklist.bed \
1>logs/estimate_read_filtering.log 2>&1
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

```
estimate_read_filtering <-
  read.delim("../quality_control/estimate_read_filtering.tsv")
knitr::kable(estimate_read_filtering)
```

3.5 使用 ATACseqQC 进行 ATAC-seq 数据质控

3.5.1 导入样本信息表

```
library(tidyverse)
library(ATACseqQC)
library(GenomicFeatures)
sample_sheet = read.csv( file =
  "../ATAC-seq-human/sample_sheet.csv") %>%
  mutate(bamReads = str_c("../ATAC-seq-human/", bamReads))
sample_sheet
```

3.5.2 Fragment size 分布

```
fragSize <- fragSizeDist( bamFiles = sample_sheet$bamReads,
  bamFiles.labels = sample_sheet$SampleID )
```

3.5.3 NFR、TSS Score 计算

用 GTF 文件构建 TxDb 对象

```
txdb <- makeTxDbFromGFF("../ATAC-seq-human/ref/genes_longest.gtf",
  format = "gtf" )
txs <- transcripts(txdb)
```

#PT score

```
gal <- readBamFile(sample_sheet$bamReads[1], bigFile=TRUE)
pt <- PTscore(gal, txs)
```

```
plot(pt$log2meanCoverage, pt$PT_score,
      xlab="log2 mean coverage",
      ylab="Promoter vs Transcript")
```

#NFR score

```
nfr <- NFRscore(gal, txs)
plot(nfr$log2meanCoverage, nfr$NFR_score,
      xlab="log2 mean coverage",
      ylab="Nucleosome Free Regions score",
      main="NFRscore for 200bp flanking TSSs",
      xlim=c(-10, 0), ylim=c(-5, 5))
```

#TSS score

```
tsse <- TSSEscore(gal, txs)
tsse$TSSEscore
```

```
plot(100*(-9:10-.5), tsse$values, type="b", xlab="distance to TSS",
      ylab="aggregate TSS score")
```

四、DeepTools 绘图

4.1 bam 转换成 bigwig

```
bamCoverage -p 1 \
  --bam clean_bams/XX_final.bam \
  -o clean_bams/XX.bw \
  --effectiveGenomeSize 119481543 \
  --binSize 50 \
  --normalizeUsing RPKM \
  1>logs/XX_convert_bam_to_bigwig.log 2>&1
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

bedGraph 转换成 bigwig

```
bedGraphToBigWig \
  raw_peaks/XX_rep1_treat_pileup.bdg \
  #此处以人的索引为参考，若是其他物种，需更换成其他物种索引名称
  ref/hg38.fa.fai \
  raw_peaks/XX_rep1_treat_pileup.bw
```

4.2 reference-point 图 (TSS Heatmap 图)

```
computeMatrix reference-point \
  -S clean_bams/XX.bw \
  --samplesLabel XX
  -R ref/genes_longest.bed6 ref/genes_shuffle.bed6 \
  --referencePoint TSS \
  -b 5000 -a 5000 \
  --binSize 50 \
  -o deeptools/tss_matrix.gz \
  -p 1
1>logs/plot_heatmap_reference_point.log 2>&1
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

```
PlotHeatmap \
  -m deeptools/tss_matrix.gz \
  -o deeptools/tss_heatmap.pdf \
  --missingDataColor 0.5 \
  1>>logs/plot_heatmap_reference_point.log 2>&1
```

4.3 scale-regions 图

```
computeMatrix scale-regions \
  -S clean_bams/XX.bw
  --samplesLabel XX
  -R ref/genes_longest.bed6 ref/genes_shuffle.bed6 \
  --regionBodyLength 4000 \
  -b 2000 -a 2000 \
  --binSize 50 \
  -o deeptools/tss_tes_matrix.gz \
  -p 1 \
  1>logs/plot_heatmap_scale_regions.log 2>&1
```

```
plotHeatmap \
  -m deeptools/tss_tes_matrix.gz \
  -o deeptools/tss_tes_heatmap.pdf \
  --missingDataColor 0.5 \
  1>>logs/plot_heatmap_scale_regions.log 2>&1
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

4.4 plotCorrelation 图（有生物学重复时绘制）

```
multiBigwigSummary BED-file \
  --bwfiles clean_bams/XX.bw \
  --labels XX XX \
  --BED ref/genes_longest.bed6 \
  -o clean_bams/bw_summary.gz \
  -p 1 \
1>logs/summarize_multiple_bigwigs.log 2>&1
```

```
plotCorrelation \
  -in clean_bams/bw_summary.gz \
  -o deeptools/sample_correlation.pdf \
  --corMethod pearson \
  --whatToPlot heatmap \
  -min 0.5 \
  --plotTitle "Pearson Correlation of Samples" \
  --outFileCorMatrix deeptools/sample_correlation.tab \
1>logs/generate_correlation_plots.log 2>&1
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

五、使用 MACS3 检测 PEAKS

5.1 ATAC call peak 流程

```
macs3 callpeak \
  -g 2913022398 \
  -t clean_bams/XX_rep1_final.bam \
  --name raw_peaks/XX_rep1 \
  --format BAM \
  --keep-dup all \
  --qvalue 0.075 \
  --cutoff-analysis \
  --broad \
  --nomodel --shift -100 --extsize 200 \
1>logs/XX_rep1_callpeak_with_mac3.log 2>&1
```

- ◆ ATAC-seq 没有 input, 不需要 -c
- ◆ --nomodel --shift -100 --extsize 200 通常关心的是酶切位点, 所以要设置这几个参数
- ◆ --format BAM 即使是 PE 测序, 也不能设置 BAMPE, 否则会使用 PE 的 fragment size

5.2 CUT&Tag/ChIP-seq call peak 流程

```
macs3 callpeak \
  -g 119481543 \
  -t clean_bams/XX_final.bam \
  -c clean_bams/XX_final.bam \
  --name raw_peaks/XX_rep1 \
  --format BAM \
  --keep-dup all \
  --qvalue 0.075 \
  --cutoff-analysis \
  1>logs/XX_callpeak_with_mac3.log 2>&1
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

- ◆ -g: 有效基因组大小: 参考 deeptools
- ◆ --format : SE 选 BAM, PE 选 BAMPE
- ◆ --keep-dup: 由于之前已经去除了 dup, 这里选 all
- ◆ --qvalue 和 --pvalue 是互斥的, 设置 qvalue 不要设置 pvalue, 默认 0.05, 由于后面要进行 IDR 分析, 先设置成 0.075 后面再过滤
- ◆ --cutoff-analysis: 帮助选择正确的截断值

六、Peak 过滤和筛选

6.1 方法 1: cutoff 过滤

如果没有生物学重复, 就只能使用 cutoff 进行过滤。

```
read.table(file = "../raw_peaks/xx_cutoff_analysis.txt", header = T)
```

通过 cutoff analysis 可以选择一个合适的 qscore 阈值, 另外还应该选择一个合适的 fold enrichment 阈值, 对数据进行过滤。

```
awk '$9>3' \
  raw_peaks/XX_peaks.narrowPeak \
  > clean_peaks/cutoff/XX_peaks.narrowPeak
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

如果没有生物学重复, 过滤后的数据可直接用于 motif 分析、peaks 注释等后续分析。如果有生物学重复, 还需要进一步的处理。

6.2 方法 2: Intersect

使用 bedtools intersect 求两个重复的交集。建议是先用 cutoff 过滤再求交集。

```
bedtools intersect \
  -f 0.5 \ # 重叠百分比
  -r \ # 相互重叠
  -a clean_peaks/cutoff/XX_rep1_peaks.narrowPeak \
  -b clean_peaks/cutoff/XX_rep2_peaks.narrowPeak \
  -wa \ # 输出 A 文件
> clean_peaks/intersect/XX_peaks.narrowPeak
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

6.2 方法 3: IDR

使用软件 IDR 进行 IDR 分析。

```
idr \
  --samples \
  XX_rep1_peaks.narrowPeak \
  XX_rep2_peaks.narrowPeak \
  --idr-threshold 0.05 \
  --output-file clean_peaks/idr/XX_true_rep_idr.txt \
  --plot \
  --input-file-type narrowPeak \
  --rank p.value \
  1>logs/XX_select_peaks_by_idr.log 2>&1
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

提取通过 IDR 阈值的 Peak 转换为 narrowPeak 格式。

```
awk \
  -v OFS="\t" \
  'BEGIN {FS=OFS} \
  { $4=$1":"$2"_"$3; print $1, $2, $3, $4, $5, $6, $7, $8, $9, $10 }'\
  clean_peaks/idr/XX_true_rep_idr.txt | \
  sort -k1,1 -k2,2n -k3,3n \
  > clean_peaks/idr/XX_peaks.narrowPeak
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

七、蛋白结合位点 Motif 分析

模体 (motif) 是生物学中描述 DNA、RNA 或蛋白质序列局部保守区域的核心概念。本章节中的 Motif 主要指转录因子结合的 DNA 序列。转录因子结合的 DNA 序列具有保守性，

可通过结合序列来推断对应的转录因子。

提取 Peaks 序列：

```
sort -k8,8nr clean_peaks/idr/XX_peaks.narrowPeak | \
head -n 1000 | \
bedtools getfasta -fi ref/genome.fa -bed - \
> clean_peaks/idr/XX_peaks.fa
```

提取 summit 两端 100 bp：

```
sort -k8,8nr clean_peaks/idr/XX_peaks.narrowPeak | \
head -n 1000 | \
awk -v OFS='\t' -v flank=50 \
'{print $1, $2+$10-flank, $2+$10+flank+1}' | \
awk '$2>=0' | \
bedtools getfasta -fi ref/genome.fa -bed - \
> clean_peaks/idr/XX_summit.fa
```

#XX 表示此处可以根据自己需求自行命名或者使用前面流程自行命名的名称

在 MEME 网页版中完成 motif 预测，tomtom 搜库。

```
fimo mymotif.txt ref/genome.fa
```

其中 mymotif.txt 是 Minimal MEME 格式的 motif 信息。

八、Peak 注释

Peak 注释的基本原理是：首先通过就近原则，将 peak 关联到距离最近的基因上，然后利用公共数据库中收集的基因功能信息，对基因进行注释。最后利用 GO、KEGG 提供的基因-信号通路映射关系，结合适当的统计学方法，将基因与信号通路关联起来。

8.1 使用 ChIPseeker 注释 Peaks

```
library(tidyverse)
library(ChIPseeker)
library(GenomicFeatures)
# 用 GTF 文件构建 TxDb 对象
txdb <- makeTxDbFromGFF(".././ref/genes_longest.gtf", format =
"gtf" )
peak = readPeakFile(".././clean_peaks/idr/XX_peaks.narrowPeak")
peakAnno = annotatePeak( peak = peak, TxDb = txdb )
peakAnno_df = as.data.frame(peakAnno)
```


```
peakAnno <- annotatePeak( peak, tssRegion=c(-2000, 50), TxDb=txdb,
  level="gene", flankDistance = 5000, genomicAnnotationPriority =
  c("Promoter", "5UTR", "3UTR", "Exon", "Intron", "Downstream",
  "Intergenic") )
peakAnno_df <- as_tibble(peakAnno)
plotAnnoPie(peakAnno)#出现 peak 所在基因不同位置占比的饼图
plotAnnoBar(peakAnno)#出现 peak 所在基因不同位置占比的柱状图
dplyr::select(peakAnno_df, c(1:6, 13:20)) %>%
  filter(V4=="chr1:56803_57743")
```

8.2 使用 UROPA 进行 Peaks 注释

UROPA 能够更灵活的对 Peaks 进行注释，满足所有自定义需求。

```
uropa \
--bed clean_peaks/idr/XX_peaks.narrowPeak \
--gtf ref/genes_longest.gtf \
--feature gene exon UTR \
--feature-anchor start center end \
--distance 100000 100000 \
--relative-location Upstream Downstream \
OverlapStart OverlapEnd \
PeakInsideFeature FeatureInsidePeak \
--show-attributes gene_id \
--outdir peak_annotation
```

- ◆ feature: GTF 第三列，通常选择 gene
- ◆ feature.anchor: ['start' , 'center' , 'end']
- ◆ distance: [100000,10000] 上游 100000，下游 10000
- ◆ strand: ['ignore' , 'same' , 'opposite']
- ◆ relative-location: ['Upstream' , 'Downstream' , 'OverlapStart' , 'OverlapEnd' , 'PeakInsideFeature' , 'FeatureInsidePeak']



```
library(tidyverse)
XX_peaks_finalhits <- read_delim
```

```
(("../..peak_annotation/XX_peaks_finalhits.txt", delim = "\t",
escape_double = FALSE, trim_ws = TRUE)
group_by(XX_peaks_finalhits, relative_location) %>%
  summarise(count = n())
library(tidyverse) XX_peaks_finalhits_summary <-
  group_by(XX_peaks_finalhits, relative_location) %>%
  summarise(count = n())
XX_peaks_finalhits_summary$fraction <-
XX_peaks_finalhits_summary$count /
  sum(XX_peaks_finalhits_summary$count)
# Create a basic pie chart
ggplot(XX_peaks_finalhits_summary, aes(x = "", y = fraction, fill =
  relative_location)) + geom_bar(stat = "identity", width = 1, color
= "white") + coord_polar("y", start = 0) + theme_void() +
  scale_fill_brewer(palette = "Set1") + theme(legend.title =
  element_blank()) + labs(fill = "Relative Location")
```

8.3 合并生成多样本共识 Peaks

合并所有 bed

```
cat clean_peaks/idr/XX_peaks.narrowPeak
clean_peaks/idr/XXX_peaks.narrowPeak >
clean_peaks/merge/cat_peaks.bed
```

按照基因组染色体顺序排列

```
bedtools sort \
-i clean_peaks/merge/cat_peaks.bed \
-g ref/genome.fa.fai \
> clean_peaks/merge/cat_sorted_peaks.bed
```

合并

```
bedtools merge \
-i clean_peaks/merge/cat_sorted_peaks.bed \
> clean_peaks/merge/merged_peaks.bed
```

转化为 saf 格式，用于 featureCounts 定量

```
awk 'OFS="\t" \ {print $1":"$2+1"-"$3, $1, $2+1, $3, "."}' \
clean_peaks/merge/merged_peaks.bed \
> clean_peaks/merge/merged_peaks.saf
```

九、使用 featureCounts 定量

```
Rscript software/RunFeatureCounts/run-featurecounts.R \
  -b clean_bams/XX_rep1_final.bam \
  --saf clean_peaks/merge/merged_peaks.saf \
  --isPairedEnd FALSE \
  -o counts/XX_rep1 \
  1>logs/XX_rep1_run_feature_counts.log 2>&1
```

FRIP 值统计

```
ls logs/*counts*.log logs/XX_rep1_run_feature_counts.log
logs/XXX_rep1_run_feature_counts.log
logs/XX_rep2_run_feature_counts.log
logs/XXX_rep2_run_feature_counts.log
$ cat logs/*counts*.log | grep "Successfully assigned alignments"
```

合并丰度矩阵，并进行 TMM

```
ls counts/XX_rep1.count \
  counts/XX_rep2.count \
  counts/XXX_rep1.count \
  counts/XXX_rep2.count >counts/count.fofn
perl software/RunFeatureCounts/abundance_estimates_to_matrix.pl \
  --est_method featureCounts \
  --quant_files counts/count.fofn \
  --out_prefix counts/merged_peaks \
  1>logs/create_count_matrix.log 2>&1
```

```
library(PCAtools)
```

```
library(tidyverse)
```

```
# 导入 tpm
tpm = read.table(file = "../counts/merged_peaks.TMM.TPM.matrix")
# 导入样本信息表
sample_info = read.csv(file = file("../sample_sheet.csv")) %>%
  column_to_rownames(var = "SampleID")
# PCA 分析
p = pca(tpm, metadata = sample_info)
# 画图
biplot(p, colby = "Factor")
```

```
sample_cor = cor(tpm)
```

```
library(pheatmap)
pheatmap(sample_cor)
```

十、差异分析

日常实验中，经常会碰到实验样本有组别差异，可能设置了不同的时间点或者不同处理的样本，这时需要找寻不同组别样品间 peak 的差异，以表征不同样品组间染色质开放性的差异。

10.1 差异 peak 分析

```
run_DE_analysis.pl \
  -m counts/merged_peaks.counts.matrix \
  --method edgeR \
  -s samples.txt \
  --contrasts contrasts.txt \
  -o diff_analysis/edgeR \
  1>logs/run_edgeR.log 2>&1
```

分析结果

```
library(tidyverse)

diff_peaks = read.table( file =
  "../diff_peaks/XX_vs_XXX.edgeR.DE_results", header = T)
```

10.2 差异 peak 注释

提取有用信息

```
awk 'BEGIN{OFS="\t"}{print $4,$7,$11,$12,$13,$14,$15,$48}' \
  diff_peaks_annotation/XX_vs_XXX_finalhits.txt \ >
  diff_peaks_annotation/XX_vs_XXX_finalhits2.txt
```

```
diff_peaks_anno <- read.table( file =
  "../diff_peaks_annotation/XX_vs_XXX_ finalhits2.txt", header
  = T)
```

10.3 富集分析

```
gene = inner_join(diff_peaks, diff_peaks_anno, by =
```

```

c("PeakID"="peak_id")) %>%
filter(Padj < 0.05) %>%
filter(!is.na(gene_id)) %>%
pull(gene_id)
gene = unique(gene)

library(org.At.tair.db)

library(clusterProfiler)

ego = enrichGO( gene = gene, OrgDb = org.At.tair.db, keyType = "TAIR",
  pvalueCutoff = 1, qvalueCutoff = 1 )
as.data.frame(ego)

barplot(ego)

```

10.4 使用 DiffBind 进行差异分析

```

library(DiffBind)

library(tidyverse)

读取样本信息表
sampleSheet = read.csv(file = ".././sample_sheet.csv")
sampleSheet = sampleSheet %>%
  mutate( bamReads = str_c(".././", bamReads),
    Peaks = str_c(".././", Peaks),
    bamControl = str_c(".././", bamControl) )
sampleSheet

构建 DBA 对象
diff_bind_obj <- dba(sampleSheet=sampleSheet,
  config = data.frame( doBlacklist = FALSE, doGreylist = FALSE ),
  bRemoveM = FALSE, bRemoveRandom = FALSE )

diff_bind_obj <- dba.count(diff_bind_obj,
  summits = 200, # 峰宽 = 2 *
  summits + 1 bUseSummarizeOverlaps = TRUE, # 更准, 更慢
  score = DBA_SCORE_RPKM
)

```

```
diff_bind_obj <- dba.normalize(diff_bind_obj,  
  normalize = DBA_NORM_TMM )
```

提取 peaks 矩阵

```
peaks_fpkms <- diff_bind_obj$binding %>%  
  as_tibble() %>%  
  mutate(peak_id = str_c('chr', CHR, ':', START, '_', END)) %>%  
  column_to_rownames(var = "peak_id") %>%  
  select(-c('CHR', 'START', 'END'))
```

样本相关系数

```
library(corrplot)
```

```
corrplot(cor(peaks_fpkms), addCoef.col = "white")
```

样本 PCA

```
library(PCAtools)
```

```
pca <- pca(peaks_fpkms,  
  metadata = column_to_rownames(sampleSheet, var = "SampleID"))
```

```
biplot(pca, colby = "Factor" )
```

明确指定一组对照做差异分析

```
diff_bind_obj <- dba.contrast(diff_bind_obj,  
  contrast = c("Condition", "XX", "XXX"), minMembers = 2 )
```

```
dba.contrast(diff_bind_obj, categories=DBA_CONDITION, minMembers=2)
```

差异结合位点分析

```
diff_bind_obj <- dba.analyze(diff_bind_obj)
```

```
dba.show(diff_bind_obj, bContrasts = T)
```

提取差异分析结果

```
diff_bind_summary = dba.show(diff_bind_obj, bContrasts = T)  
diff_bind_summary
```

```
diff_bind_result <- dba.report(diff_bind_obj)
diff_bind_table <- as.data.frame(diff_bind_result)
```

画图

```
dba.plotVenn(diff_bind_obj, contrast=1, bDB=TRUE, bGain=TRUE,
  bLoss=TRUE, bAll=FALSE)
```

```
dba.plotVolcano(diff_bind_obj, contrast = 1 )
```

十一、足迹分析

11.1 TF 的足迹分析

足迹是指转录因子 TF 在 DNA 上的结合位置，由于 TF 的动态结合，Tn5 转座酶切割到此区域的概率低于两侧的完全开放区，因此可通过测序深度的差异识别出此位置，足迹分析的目就是从数据中鉴别出这些位置。

```
library(tidyverse)
```

#合并 BAM。TOBIAS 不支持生物学重复，需要合并到一起。

```
samtools merge -o clean_bams/XX_merged.bam \
  clean_bams/XX_rep1_final.bam \
samtools index clean_bams/XX_merged.bam
```

#由于 Tn5 结合具有偏好性，需要进行矫正。输入 merged.bam 输出 corrected.bw。

```
TOBIAS ATACorrect \
  --bam clean_bams/XX_merged.bam \
  --genome ref/hg38.fa \
  --peaks clean_peaks/merge/merged_peaks.bed \
  --outdir footprinting \
  --prefix Diabetic_hs \
  --cores 1 \
1>logs/XX_ATACorrect.log 2>&1
```

#计算单碱基水平的足迹分数，需要注意分数越高并不代表就有足迹。如果没有 TF 足迹，分数会收敛到附近平均的开放性水平，有足迹就会升高。

```
TOBIAS ScoreBigwig \
  --signal footprinting/XX_corrected.bw \
  --regions clean_peaks/merge/merged_peaks.bed \
  --output footprinting/XX_footprints.bw \
  --cores 1 \
1>logs/XX_FootprintScores.log 2>&1
```

#输出的 bigwig 格式不能直接查看，可以导入到 IGV 查看。可以使用 bigWigToBedGraph 转化为文本格式。

```
bigWigToBedGraph XX_footprints.bw XX_footprints.bedGraph
```

#BINDetect 首先在所有开发区域搜索已知的 motif 基序，确定可能的结合位点。再结合足迹分数，推测是否可能有 TF 结合。

```
TOBIAS BINDetect \
  --motifs test.meme \ # motif 基序
  --signals footprinting/XX_footprints.bw \
  footprinting/XXX_footprints.bw \
  --genome ref/hg38.fa \
  --peaks clean_peaks/merge/merged_peaks.bed \ # 开放区域
  --outdir footprinting \
  --cond_names XX XXX \
  --cores 1 1>logs/BINDetect.log 2>&1
```

#输出文件

```
library(readr)
bindetect_results <-
  read_delim("../ATAC-seq-human/footprinting/bindetect_results.txt",
    delim = "\t", escape_double = FALSE, trim_ws = TRUE)
```

11.2 单个 motif 分析

以 EHF 结合位点为例来进行分析展示

```
EHF_overview <-
  read_delim("~/workspace/20231225_ChIP_ATAC/ATAC-seq-human/footprinting/_EHF_HUMAN.H11MO.0.B/_EHF_HUMAN.H11MO.0.B_overview.txt",
    delim = "\t", escape_double = FALSE, trim_ws = TRUE)
```

```
library(readr)
EHF_Diabetic_bound_bed <-
  read_delim("~/workspace/20231225_ChIP_ATAC/ATAC-seq-human/footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_Diabetic_hsbound.bed", delim = "\t", escape_double = FALSE, col_names = FALSE, trim_ws = TRUE) %>%
  set_names(c("TFBS_chr", "TFBS_start", "TFBS_end", "TFBS_name", "TFBS_score", "TFBS_strand", "peak_chr", "peak_start", "peak_end",
```

```
"footprint_score"))
```

#画图

```
TOBIAS PlotAggregate \
```

```
--TFBS
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_Diabetic_hs_bound.bed \
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_Diabetic_hs_unbound.bed \
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_Healthy_hs_bound.bed \
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_Healthy_hs_unbound.bed \
```

```
--TFBS-labels Diabetic_bound Diabetic_unbound Healthy_bound
```

```
Healthy_unbound \
```

```
--signals footprinting/Diabetic_hs_corrected.bw \
```

```
footprinting/Diabetic_hs_uncorrected.bw \
```

```
footprinting/Healthy_hs_corrected.bw \
```

```
footprinting/Healthy_hs_uncorrected.bw \
```

```
--signal-labels Diabetic_corrected Diabetic_uncorrected
```

```
Healthy_corrected corrected_uncorrected \
```

```
--output
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/_EHF_HUMAN.H11MO.0.B_PlotAggregate.pdf \
```

```
--share_y both \
```

```
--plot_boundaries \
```

```
--signal-on-x
```

#heatmap 图

```
TOBIAS PlotHeatmap \
```

```
--TFBS
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_Diabetic_hs_bound.bed \
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_Diabetic_hs_unbound.bed \
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_Healthy_hs_bound.bed \
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_Healthy_hs_unbound.bed \
```

```
hy_hs_unbound.bed \
--TFBS-labels Diabetic_bound Diabetic_unbound Healthy_bound
Healthy_unbound \
--signals footprinting/Diabetic_hs_corrected.bw \
footprinting/Diabetic_hs_uncorrected.bw \
footprinting/Healthy_hs_corrected.bw \
footprinting/Healthy_hs_uncorrected.bw \
--signal-labels Diabetic_corrected Diabetic_uncorrected
Healthy_corrected corrected_uncorrected \
--output
footprinting/_EHF_HUMAN.H11MO.0.B/_EHF_HUMAN.H11MO.0.B_PlotHeatma
p.pdf --plot-boundaries \
--share-colorbar \
--sort-by -1
```

#筛选前 20 个进行可视化

```
EHF_selected <- filter(EHF_overview, Healthy_hs_bound +
                        Diabetic_hs_bound == 2) %>%
arrange(desc(Healthy_hs_score)) %>%
slice(1:20)

plot_regions <- mutate(EHF_selected, peak_chr, plot_start = peak_start
                        - 1000, plot_end = peak_end + 1000) %>%
select(peak_chr, plot_start, plot_end)
write.table(plot_regions, file =
            "../ATAC-seq-human/plot_regions.bed", sep = "\t",
            row.names = F, col.names = F, quote = F)

singularity exec ../PeakSnake/sifs/tobias_20231231.sif TOBIAS
PlotTracks \
--bigwigs raw_peaks/*_treat_pileup.bw \
--bigwigs footprinting/*_corrected.bw \
--bigwigs footprinting/*_footprints.bw \
--regions plot_regions.bed \
--sites
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_all.b
ed \
--highlight
```

```
footprinting/_EHF_HUMAN.H11MO.0.B/beds/_EHF_HUMAN.H11MO.0.B_all.b
ed \
--gtf ref/genes_longest.gtf \
--colors red darkblue red darkblue red darkblue
```


十二、IGV 可视化

Integrative Genomics Viewer (IGV)是由 Broad 研究院的研究人员开发的一款功能强大的综合性基因组学可视化工具。借助于此工具，从事生物信息的科研工作者就可以轻松的分析查看多种基因组数据。除了直观的查看序列信息及遗传密码中的序列变化或突变外，还可以查看拷贝数变化、染色质沉淀数据和表观遗传学修饰等。使用者可以选择多种显示模式，以 heat map、柱状图、散点图或其他形式查看数据。

IGV 软件在 CUT&Tag 实验后续结果查看中也是应用较多的软件。另外，IGV 软件为免费软件，在 mac 系统、windows 系统以及 linux 系统上都可以使用。本操作以 IGV for Windows 来进行可视化操作说明。

1) 软件安装：下载软件后，解压即可。

打开网站 <http://software.broadinstitute.org/software/igv/download>，点击 IGV for Windows，进入下载页面。下载后的文件，解压后即可使用。



解压后，双击 igv.bat，进入 IGV 可视化界面。若出现黑框，直接关闭即可。稍微等待后，即可出现 IGV 可视化界面。


名称	修改日期	类型	大小
jdk-11	2022/8/16 15:00	文件夹	
lib	2022/8/16 15:01	文件夹	
igv.args	2022/8/9 5:42	ARGS 文件	1 KB
igv.bat	2022/8/9 5:42	Windows 批处理...	2 KB
IGV_64.ico	2022/8/9 5:42	ICO 图片文件	17 KB
igv-launcher.bat	2022/8/9 5:42	Windows 批处理...	1 KB
readme.txt	2022/8/9 5:42	文本文档	5 KB
uninstaller.exe	2022/8/16 15:01	应用程序	54 KB

2) IGV 软件兼容的数据格式如下表


Source Data	File Formats
ChIP-seq, RNA-seq	TDF
Copy number	CN format, SNP format
Gene expression data	GCT format, RES format
Genome annotations	GFF or GFF3 format, BED format
GISTIC data	GISTIC format
LOH data	LOH format
Mutation data	MUT format
RNAi data	GCT format
Segmented data	SEG format, CBS format
Sequence alignment data	SAM format, BAM format
Any numeric data	IGV format, TAB format, WIG format

一般 CUT&Tag 实验主要使用 IGV 软件查看测序结果的 peak 可视化情况以及 peak 的注释情况（基因是否显著富集）。需要的文件为研究物种的基因组 fa 文件、peak 注释 bed 文件以及 reads 分布的 tdf 文件以及基因组的基因注释 gff 文件。

选择所使用的基因组。IGV 所需的基因组，可以从文件导入、基因组文件链接（见 3.1.1 或 3.1.2）导入或者直接从 IGV 内部已嵌入的基因组进行选择。




图：IGV Genomes 选项




图：IGV 中已嵌入的基因组

3) 导入 peak 注释 bed 文件以及 reads 分布的 tdf 文件。有时候数据分析时没有 tdf 文件，只有 bam 文件，这时，最好能将 bam 文件转化为 tdf 文件。Bam 文件一般都很大，而 tdf 文件相对来说比较小，可以提高展示效率（若直接得到的 bw 或 bigwig 文件，无需转换，直接导入 IGV 即可）。



图：导入文件 step1-"File"-"Load from file"




图：导入文件 step2-找到对应数据存放文件夹-点击对应文件-“打开”




图：导入文件：导入文件可以是 bw 或者 tdf 文件，导入之后，可以选择基因组上不同染色体以及染色体上基因的位置信息，选择后，IGV 上会展示所选择内容的 peak 富集情况。

4) (可选)将 bam 文件转化为 tdf 文件。点击 IGV 软件的“Tools”下拉框中的“Run igvtools”，在跳转的页面，选择需要转化的 bam 文件。




点击“Command”右侧下拉框的“Count”、“Input File”右侧的“Browse”选择所需转换的 bam 文件、“Output File”右侧会自动输出文件名后，点击“Run”开始转换。“Messages”窗口会显示转换进度，当出现“Done”，即表示转换完毕，转换完毕后，点击“Close”即可关闭窗口。


5) 导入 GFF 文件。需要查看基因组不同位置处的基因富集情况时，需要导入基因组的 gff 文件。根据 3.1.1 或 3.1.2 步骤下载 gff 文件。之后选择“File” - “Load from file” -选择 gff 文件所在文件夹-点击所需 gff 文件-“打开”，导入 gff 文件。




图：导入文件 step1-“File”-“Load from file”



图：导入文件 step2-找到对应数据存放文件夹-点击对应文件-“打开”



图：导入文件 step3: 因下载的 gtf 文件未构建 index 索引，会有弹窗提醒，点击“Cancel”后，IGV 会自动导入 gtf 文件，但是导入时间需要等待几分钟（根据电脑性能，打开时间不一样）



图：导入文件 step4: 选择染色体位置或者输入基因名称，能看到不同基因的 peak 富集情况

附录四：ATAC、ChIP-seq 或 CUT&Tag 公共数据库

ATAC 和 CUT&Tag 实验后的数据整理阶段，通常会使用同物种或者不同物种的相同研究进行结果的佐证，这个时候，需要对同物种或者不同物种的 ATAC 或者 CUT&Tag 数据进行下载。

下面给大家介绍不同物种的一些常用 ATAC 和 CUT&Tag 数据库，方便大家快速找到想要的对比数据（目前 CUT&Tag 大多是参考 ChIP-seq 的数据）。

- ◆ NCBI: NCBI (National Center for Biotechnology Information, 美国国家生物技术信息中心) 是一个提供生物技术信息的综合平台, 隶属于美国国家卫生研究院 (NIH) 的国家医学图书馆 (NLM)。NCBI 上的数据类型比较多, 基因组、表观组、蛋白组、转录组等, 各种物种都有, 需要对数据进行筛选。(网址: <https://www.ncbi.nlm.nih.gov/>)。
- ◆ SRA: SRA (Sequence ReadArchive) 数据库是 NCBI (National Center for Biotechnology Information) 旗下用于存储高通量测序数据的子库。已发布 6019 套人的 ATAC-seq 数据, 其次是小鼠。植物界的拟南芥、水稻、高粱、苜蓿、小米、番茄、玉米各有少量数据。
- ◆ TCGA: 癌症基因组图谱数据库。从 TCGA 数据库下载 ATAC-seq 数据, 可以选择下载 raw count 或 normalize count。下载的数据可以得到每个肿瘤的 ATAC 数据矩阵, 包含染色体、peak 的起始位置、peak 的名字和每个样品在 peak 中的表达量(网址: <https://www.cancer.gov/ccg/research/genome-sequencing/tcga>)。

- ◆ ENCODE: DNA 元件百科全书。Encode 共享了大量的组学数据, 还开源了自己的数据分析 pipeline。提供了从原始的 fastq 数据到 peak calling 结束的基础分析功能, 但缺少了下游的差异分析和 motif 分析 (网址: <https://www.encodeproject.org/>)。数据库包含人、小鼠、线虫和果蝇的各种组学数据 (ChIP、ATAC、单细胞、转录组等)。

- ◆ ATACdb : ATACdb 是一个全面的人类染色质可开放性数据库, 旨在帮助研究人员深入理解表观基因组机制, 并在可开放染色质区域发现更多的生物功能。该数据库包含来自 1493 个 ATAC-seq 样本的 52078883 个区域, 这些样本来自 NCBI GEO/SRA 的 2200 多个与 ATAC-seq 数据相关的染色质可开放性样本。ATACdb 为染色质可开放区提供详细的遗传注释, 包括超级增强子、典型增强子、转录因子 (TF)、常见单核苷酸多态性 (SNP)、风险 SNP、eQTL、LD SNP、甲基化、染色质相互作用和 TAD (网址: <http://www.lipathway.net/ATACdb>)。该数据库只包含人和小鼠的 ATAC 数据。

- ◆ scATAC-Ref: 单细胞 ATAC 数据库, 包含物种有: 人、小鼠、斑马鱼、玉米和拟南芥 (网址: <https://bio.lipathway.net/scATAC-Ref/>)。

- ◆ GTRD: (Gene Transcription Regulation Database) 是一个全面的转录因子 ChIP-seq 数据库, 收集了来自 SRA、GEO、ENCODE 等公共数据库的转录因子相关数据。该数据库采用标准流程进行 peak calling 分析, 并基于已有的转录因子 motif 数据, 预测了转录因子结合位点 (TFBS)。GTRD 包含 ATAC、ChIP-seq、CAGE、DNase-seq 和 FAIRE-seq 数据 (网址: <https://gtrd.biouml.org/#!>)。该数据库包含人、小鼠、斑马鱼、酵母、拟南芥等物种的数据。

- ◆ ChIP-Atlas: ChIP-Atlas 是一个基于公共 ChIP-seq 数据进行分析和挖掘的在线平台。它收集并整理了 SRA 数据库中的大量 ChIP-seq 数据, 并基于这些原始数据进行了后续分析, 将分析结果整理成在线服务, 方便用户进行检索与查询 (网址: <https://chip-atlas.org/>)。该网站有 ChIP-seq、ATAC-seq 和甲基化数据。该数据库包含人、小鼠、褐家鼠、果蝇、线虫和酵母的数据。

- ◆ Cistrome DB: Cistrome DB 是提供一个基因组顺式作用元件分析的综合性数据库, 通过收集来自 GEO、ENCODE 等公共数据库中的 chip_seq, DNase_seq, ATAC_seq 原始数据, 采用统一的分析方法, 用 bwa 比对参考基因组, 然后采用 macs2 进行 peak calling, 将分析的结果加以整合, 做成了在线数据库, 整个数据库的构建过程和功能模块示意如下。该数据库存放人类和小鼠的 ChIP-seq、ATAC-seq 和 DNase-seq 数据的资源库 (网址: <http://cistrome.org/db/#/>)。

- ◆ ChIP-Hub: 南京大学发表植物调控组学综合分析平台 ChIP-Hub (网址: <https://biobigdata.nju.edu.cn/ChIPHub/>) 收集了超过 40 个物种, 总量大于 10,000

套植物调控组学数据，其中包括 ChIP-seq、DAP-seq、DNase-seq 和 ATAC-seq 等。物种包含拟南芥、玉米、大豆、水稻、番茄等超过 40 个物种的数据。

- ◆ RiceENCODE: RiceENCODE 数据库是由华中农业大学发布的一个水稻表观基因组学数据库。该数据库收集了包括 ChIP-seq、ATAC-seq、MNase-seq、FAIRE-seq、BS-seq、RNA-seq、ncRNA-seq、Hi-C 和 ChIA-PET 等共计 972 套水稻高通量组学数据。通过标准化的数据处理流程，RiceENCODE 数据库提供了多维度的高质量表观和三维基因组数据（网址：<http://glab.hzau.edu.cn/RiceENCODE/>）。
- ◆ WP-MOD: 南京林业大学生命科学学院的 WP-MOD 数据库，从 NCBI Genome、Ensembl Plant 和 Phytozome v13 等多个公共数据库收集了 373 种木本植物的基因组数据。包含 RNA-seq、sRNA-seq、ChIP-seq、ATAC-seq 和 BS-seq 数据。还利用了多种工具和程序，像 InterProScan 进行基因注释，PlantTFDB 预测转录因子，OrthoFinder 识别直系同源基因等（网址：<https://www.woodyplant.com/>）。该数据库包含酸枣、白松、金合欢尖叶、黑铁桉等 373 种禾本植物数据。
- ◆ AraENCODE: 拟南芥综合表观基因组数据库（网址：<http://glab.hzau.edu.cn/AraENCODE>），共包含 4,511 个数据库，包括已发表的染色质构象捕获数据集（Hi-C, HiChIP），表观基因组数据集（ChIP-Seq、ATAC-Seq、FAIRE-Seq、MNase-Seq、DNase-Seq、BS-seq）和转录组数据（RNA-Seq、miRNA-Seq）。还整合了各种现有资源，例如单核苷酸多态性（SNP）、顺式调控模块和多组学关联。
- ◆ AMIR: 华中农业大学的 AMIR 是一个面向菊科植物群落的组学中心，建立了菊科第一个泛基因组、比较基因组学和转录组系统。随着菊科基因组学研究的深入，以及全基因组测序数据和表观遗传学数据（如甲基化、组蛋白修饰、ATAC-seq 和 ChIP-seq）的增加，将会用新的组学信息不断丰富 AMIR（网址：<https://yanglab.hzau.edu.cn/AMIR/genomics/genome/>）。
- ◆ ZEAMAP: 华中农业大学严建兵教授课题组整合的来自于同一玉米群体的基因组、转录组、表型组、代谢组、表观基因组、遗传变异以及遗传定位结果等多组学数据，构建了一个玉米属综合数据库 ZEAMAP（<http://www.zeamap.com/>），并内嵌了基因组“浏览器”和“搜索引擎”，实现对相关组学数据的高度集成、快速检索和智能分析。
- ◆ PCBase: Plant ChIP-seq Database (PCBase) 收集了 GEO 和 SRA 中的植物 ChIP-seq 数据，用户可以通过查询特定基因的启动子序列，识别与之相关的转录因子结合位点，并扫描全基因组的 TFBS。该数据库包含拟南芥、水稻、玉米、大豆、番茄、阿拉伯芥、棉花和衣藻的表观数据（网址：<https://pcbase.itps.ncku.edu.tw/>）。

转录因子（Transcription Factor, TF）作为调控基因转录的核心因子，通过与靶基因上游特定序列（motif）结合后，能够参与下游靶基因的表达调控。转录因子鉴定和鉴定技术：

- ◆ ATAC-seq（鉴定未知转录因子）
- ◆ CUT&Tag（已知转录因子找寻共调控转录因子或者转录因子结合位点）
- ◆ ChIP-seq（已知转录因子找寻共调控转录因子或者转录因子结合位点）
- ◆ CUT&RUN（已知转录因子找寻共调控转录因子或者转录因子结合位点）
- ◆ 酵母双杂交（鉴定未知转录因子）
- ◆ 酵母单杂（鉴定转录因子结合位点）
- ◆ 双荧光酶报告基因（验证转录因子结合位点）
- ◆ EMSA（验证转录因子结合位点）

以上技术，有一些是找寻未知转录因子，或者是鉴定转录因子结合。

分享一些整合了不同物种的数据，这些数据库提供了广泛的转录因子信息。在研究特定物种时，使用这些数据库，可以在不做表观实验，直接进行转录因子预测，并利用预测结果来判断要不要进行下一步的酵母单杂、双荧光素酶、EMSA 以及 ChIP-seq/qPCR 的验证实验。

转录因子预测信息数据库：

- ◆ PlantTFDB: 专注于植物转录因子的功能和进化研究（网址：<https://planttfdb.gao-lab.org/>）。最新版的 PlantTFDB v5.0（<http://planttfdb.cbi.pku.edu.cn/>）升级为植物调控数据和数据分析平台 PlantRegMap（<http://plantregmap.cbi.pku.edu.cn/>），该平台升级了 PlantTFDB 数据库，新版的 PlantTFDB 包含了 320,370 个转录因子，将转录因子分为 58 个家族，涵盖 165 个物种。可以按物种/基因家族查询，也可以直接在右上角直接搜索转录因子。
- ◆ PlantPAN 4.0: 探索植物转录因子和启动子的调控数据库。基因注释和启动子序列有 115 个物种，3428 个非冗余矩阵，用于 18305 个转录因子。PlantPAN 4.0 可以查看和比较不同植物物种和实验中的基因顺式调控元件之间的进化差异和相似性，还可以帮助鉴定同源基因之间的保守非编码序列。（网址：<https://plantpan.itps.ncku.edu.tw/plantpan4/index.html>）。
- ◆ AnimalTFDB: 包含 183 个动物基因组的转录因子和转录辅因子的分类和注释，涵盖 270,000 个转录因子。AnimalTFDB 有经过鉴定、分类和注释的 97 个物种全基因组水平的 125,135 个 TF 基因和 80,060 个转录辅因子基因。在里面我们可以查到动物的转录因子注释和预测数据。AnimalTFDB 根据转录因子 DNA 结合结构域（DBD），将 TF

进、TF 辅助因子功能分类。还提供多种搜索浏览方式 (Family、Species 或自定义搜索)、2 个在线预测工具 Predict TF 和 Predict TFBS (分别可以批量预测转录因子和预测 DNA 序列上的转录因子结合位点)、Blast 工具和数据下载功能, 非常实用 (网址: <https://guolab.wchscu.cn/AnimalTFDB4/#/>)。

- ◆ JASPAR: 一个广泛使用的转录因子结合位点数据库, 收集转录因子与 DNA 结合位点以及结合方式, 提供多种物种的转录因子信息。共收集了脊椎动物、植物、昆虫、线虫、真菌和尾索动物六大类不同类生物的数据, 可以用来预测转录因子与序列的结合区域。里面有 9 个子数据库, 各库内容针对不同, 对应不同来源和类别的转录因子信息 (网址: <https://jaspar.elixir.no/>)。
- ◆ dbCoRC: dbCoRC 是第一个全面的交互式 CRC 数据库, 也是核心启动因子数据库。它基于 H3K27ac ChIP-Seq 数据的计算分析, 包含来自 188 个人类和 50 个鼠类样本的 CRC 模型。利用该数据库, 我们可以获得单个样品的超级增强子 (SE)、增强子和 H3K27ac 景观、CRC 内 SE 区中每个核心转录因子 (TF) 的假定结合位点。dbCoRC 还可作为研究生理 (非疾病) 和疾病状态下的转录网络和调控回路的宝贵资源 (网址: <http://dbcorc.cam-su.org>, 提示, 网址有时候打不开, 打不开的话, 只能换其他网站了)。
- ◆ TRRUST: 是一个人工注释的转录调控网络数据库, 不仅包含转录因子对应的靶基因, 也包含了转录因子间的调控关系, 并且提供的 TF-target 互作信息。TRRUST 目前包括两个物种: 人和小鼠, 分别包含 800 个人类 TF 和 828 个小鼠 TF 的 8,444 和 6,552 个 TF 目标调节关系。它们源自 11237 篇发表的文章, 其中描述了转录调控的小规模实验研究。TRRUST 数据库还提供调节模式 (激活或抑制) 的信息, 已知有 8,972 个调控信息, 占比 59.8% (网址: <https://www.grnpedia.org/trrust/>)。
- ◆ TransmiR3.0: 是收集转录因子 (TF) -microRNA (miRNA) 的数据库, 通过它可以找到 TF 和 miRNA 之间的调控关系。其中包含从 2285 篇论文中策划的 5095 个转录因子 (TF) -miRNA 调控和来自 ChIP-seq 数据的大于 6 百万个 TF-miRNA 调控。目前, TransmiR v3.0 涵盖 29 种生物体的 3260 个 TFs、4253 个 miRNA 和 514 433 个 TF-miRNA 调控对。此外, 对来自多个物种的 miRNA 启动子序列上的 TF 位点进行基序扫描用于预测 TF-miRNA 调节, 产生 284 527 个预测的 TF-miRNA 调节。 (网址: <http://www.cuilab.cn/transmir>)。
- ◆ footprintDB: 是一个转录因子综合数据库, 收录了 8754 个去冗余的转录因子, 整合了 JASPAR 在内的 9 个数据库的 9350 个转录因子、13682 个 DNA motifs 和 35058 个 DNA 结合位点数据, 存储了 transcription factors, DNA motifs, DNA binding sites 3 种信息。通过这个数据库能够预测结合特定 DNA 位点或基序的转录因子, 以及可能被

特定 DNA 结合蛋白识别的 DNA 基序或位点(网址:<https://footprintdb.eead.csic.es/>)。

- ◆ HOCOMOCO: 是专门研究人和小鼠的数据库, 团队从超过 5000 个针对人类和小鼠转录因子的实验中获得 14000 多套 ChIP-Seq 数据集, 进行系统化的基序发现和交叉验证。目前, HOCOMOCO 共收集了 680 个人和 453 个鼠转录因子的结合 model, 其中包含 1302 个单核苷酸和 576 个二核苷酸的位置权重矩阵。(网址: <https://hocomoco11.autosome.org/>)。
- ◆ hTFtarget: 整合了 699 个转录因子的高可信度 DNA 结合序列, 其中包含 699 个 TF 的 2737 个 TFBS 基序, 是人类 TF-target 目前最全面的数据库。整合大规模的人类转录因子靶基因数据之外, 还构建了开源的人类转录因子靶基因数据库, 分析了转录因子的细胞系特异性调控、转录因子间的协作调控等, 为 TF-target 调控的研究提供了近似的一站式解决方案(网址: <https://guolab.wchscu.cn/hTFtarget/#/>)。
- ◆ KnockTF2.0: KnockTF 2.0 提供跨多个组织//细胞的 T(co)F 敲除//敲除之前/之后的全面基因表达谱数据集。它是人的全面基因表达谱 TF 击倒/基因敲除数据库, 它提供了大量与转录因子敲降/敲除相关的人类基因表达谱数据集、转录因子及其靶基因的注释信息、转录因子的上游通路信息和下游靶基因的功能注释信息, 以及转录因子绑定到靶基因启动子、增强子和超级增强子的详细信息(网址: <http://www.licpathway.net/KnockTF/index.php>)。